

---

# Ανάλυση Βιο-δεδομένων

---

Δημήτριος Ζερκελίδης 03400049    Μαρία Καϊκτζόγλου 03400052  
Κωνσταντίνα Καραϊσκού 03400054    Μαρία-Φιλίππα Τριβυζά 03400080

Τμήμα Ηλεκτρολόγων Μηχανολόγων και Μηχανικών Υπολογιστών,  
Εθνικό Μετσόβιο Πολυτεχνείο,  
Ζωγράφου 15780, Ελλάδα

Επιβλέπων  
Δρ Γεώργιος Ματσόπουλος

## 1 Εισαγωγή

Στην καθημερινή ζωή, η αναγνώριση των αντικειμένων και ο διαχωρισμός τους σε κατηγορίες είναι μια απλή, άκοπη διαδικασία θεμελιώδους σημασίας για την επιβίωση. Ωστόσο, ο τρόπος που λειτουργούν τα νεύρα για να την υποστηρίξουν συνεχίζει να έχει πολλές σκοτεινές πτυχές. Ένα από τα αντικείμενα έρευνας της γνωστικής νευροεπιστήμης είναι η εξερεύνηση των αναπαραστάσεων των αντικειμένων στον εγκέφαλο και η εύρεση συσχετισμών μεταξύ των αναπαραστάσεων στα σημεία του εγκεφάλου.

Το ανθρώπινο οπτικό σύστημα αναγνωρίζει αντικείμενα με γρήγορο τρόπο και η νευρική δραστηριότητα του ανθρώπινου εγκεφάλου παράγει σήματα, τα οποία παρέχουν πληροφορίες σχετικά με τις κατηγορίες των αντικειμένων που βλέπει ο εκάστοτε άνθρωπος. Τα εγκεφαλικά σήματα μπορούν να καταγραφούν χρησιμοποιώντας διάφορα συστήματα, όπως το ηλεκτροεγκεφαλογράφημα (EEG). Τα EEG σήματα μεταφέρουν σημαντικές πληροφορίες σχετικά με τα ερεθίσματα που διεγείρουν τον εγκέφαλο.

Το EEG είναι μια μέθοδος παρακολούθησης και καταγραφής της ηλεκτρικής δραστηριότητας του εγκεφάλου, η οποία είναι συνήθως μη επεμβατική, με τα ηλεκτρόδια τοποθετημένα στο τριχωτό της κεφαλής, αν και μερικές φορές χρησιμοποιούνται διηθητικά ηλεκτρόδια, όπως στην ηλεκτροκορτικογραφία. Συγκεκριμένα, το EEG μετρά τις διακυμάνσεις τάσης που προκύπτουν από το ιοντικό ρεύμα μέσα στους νευρώνες του εγκεφάλου. Έχει υψηλή χρονική ανάλυση (msec), χαμηλή χωρική ανάλυση και σχετικά χαμηλό κόστος νευροαπεικόνισης. Επιπλέον, οι μετρήσεις EEG είναι αρκετά μικρές, μετρούμενες σε  $\mu V$ , με τις κύριες συχνότητες ενδιαφέροντος μέχρι περίπου 30 Hertz (Hz).

Στη συγκεκριμένη εργασία μελετάμε την εκπόνηση μιας EEG έρευνας που εφάρμοσε ταξινόμηση μιας εκτέλεσης (Single Trial Classification) για τη διενέργεια Representational Similarity Analysis (RSA) κατηγορικών αναπαραστάσεων αντικειμένων στον ανθρώπινο οπτικό φλοιό. Έγινε καταγραφή των εγκεφαλικών αποκρίσεων ενώ οι συμμετέχοντες στο πείραμα έβλεπαν ένα σύνολο 72 φωτογραφιών αντικειμένων που είχαν χωριστεί σε κατηγορίες με συγκεκριμένη δομή. Το Representational Dissimilarity Matrix (RDM) που χρησιμοποιήθηκε για το RSA παρήχθη από τα confusion matrices που προέκυψαν από την εφαρμογή ενός γραμμικού ταξινομητή (LDA) πάνω σε μεμονωμένες EEG δοκιμές (trials). Επιπλέον, εκτελέστηκαν ταξινομήσεις σε υποσύνολα των εγκεφαλικών αποκρίσεων για να εντοπιστούν χωρικά (Spatial) και χρονικά (Temporal) στοιχεία του EEG, τα οποία φάνηκαν να είναι πιο χρήσιμα στο διαχωρισμό των κατηγοριών των αντικειμένων και των μεμονωμένων παραδειγμάτων (Exemplars).

Τα αποτελέσματα από τις κατηγορικές ταξινομήσεις έδειξαν ότι οι εγκεφαλικές αποκρίσεις σε εικόνες ανθρώπινων προσώπων σχημάτισαν την πιο διακριτή κατηγορία, ενώ οι αποκρίσεις σε εικόνες από τις δύο άψυχες (Inanimate) κατηγορίες σχημάτισαν μία μοναδική συστάδα (cluster). Τα αποτελέσματα από τις exem-

plar ταξινομήσεις παρήγαγαν ομοιομορφία στη δομή της κατηγορίας τους. Τα χωρικά-χρονικά υποσύνολα των αποκρίσεων του εγκεφάλου που διαχώρισαν τα exemplars μέσα σε μια κατηγορία, βρέθηκαν να διαφέρουν από εκείνα που διαχώρισαν τις κατηγορίες μεταξύ τους.

## 2 Σχετική Έρευνα

Η έννοια της ειδικότητας κατηγορίας (category specificity) στην οργάνωση της γνώσης αντικειμένων εμφανίστηκε στη δεκαετία του 1980, όταν η Warrington [2] και οι συνεργάτες της μελέτησαν για πρώτη φορά σε ασθενείς με μια πάθηση που ονόμασαν selective impairment, μια σημασιολογική κατηγορία σε σύγκριση με άλλες σημασιολογικές κατηγορίες.

Η ύπαρξη διαφορών στην εγκεφαλική δραστηριότητα που σχετίζονται με την κατηγορία έχει αποδειχθεί με διάφορες μεθόδους νευροαπεικόνισης σε υγιή άτομα, για έμψυχων έναντι άψυχων αντικειμένων και για διάφορες κατηγορίες αντικειμένων όπως πρόσωπα, μέρη σώματος, ζώα, φρούτα / λαχανικά, κτίρια, εργαλεία και έπιπλα. Η διαφοροποιημένη ενεργοποίηση (differential activation) που υποδηλώνει μια συγκεκριμένη λειτουργική οργάνωση (functional organization) έχει αποδειχθεί κατά την επεξεργασία τόσο των οπτικών όσο και των λεκτικών τρόπων διέγερσης. Για ορισμένους τύπους αντικειμένων έχει αποδειχθεί η functional organization κατά σημασιολογική κατηγορία, όπως π.χ. η category-specificity στην οπτική οδό για πρόσωπα, ή για έμψυχων έναντι άψυχων οντοτήτων. Έχει επίσης αποδειχθεί ότι τα αντικείμενα και τα αισθητηριακά ή λειτουργικά τους γνωρίσματα (όπως π.χ. οι ενέργειες που συνδέονται με εργαλεία) ενεργοποιούν τις ίδιες νευρικές περιοχές, υποδηλώνοντας ότι αυτές οι περιοχές εμπλέκονται έμμεσα στην αναπαράσταση της έννοιας (concept representation).

Πλήθος ερευνών με functional MRI δεδομένα έχει χρησιμοποιήσει ανάλυση πολλών μεταβλητών (multivariate analysis) που επιτρέπει τη θεώρηση του πλήρους χωρικού μοτίβου της εγκεφαλικής δραστηριότητας. Αυτό έχει αποδειχθεί ότι αυξάνει την ευαισθησία κατά την ανάλυση ανθρώπινων νευροαπεικονιστικών (neuroimaging) δεδομένων και μπορεί να βοηθήσει στην αποσαφήνιση της φύσης των σημασιολογικών αναπαραστάσεων. Ο στόχος της multivariate ανάλυσης είναι να μάθει ένα μοντέλο που εξηγεί καλύτερα τα παρατηρούμενα δεδομένα, συχνά ποσοτικοποιημένα ως προς την προβλεπόμενη απόδοση. Μόλις μάθει το μοντέλο, οι εκτιμημένες παράμετροι μπορούν να χρησιμοποιηθούν και να παραχθούν οι λεγόμενοι χάρτες σπουδαιότητας. Οι χάρτες σπουδαιότητας παρέχουν πληροφορία για τη σχετική σημασία των χαρακτηριστικών των δεδομένων (data features) στο χώρο και/ή στο χρόνο σε σχέση με την πρόβλεψη της πειραματικής κατάστασης σε μεμονωμένα trials. Πρόσφατα, ο van Gerven [1] και οι συνάδελφοί του εισήγαγαν μια Μπεϋζιανή προσέγγιση στην multivariate ανάλυση για την ερμηνεία των δεδομένων νευροαπεικόνισης. Η προσέγγιση καθιστά δυνατή την 1) ποσοτικοποίηση της αβεβαιότητας σχετικά με τη σχετική σημασία των χαρακτηριστικών δεδομένων και 2) την επιβολή περιορισμών στα λαμβανόμενα μοντέλα με βάση προηγούμενες νευροεπιστημονικές γνώσεις.

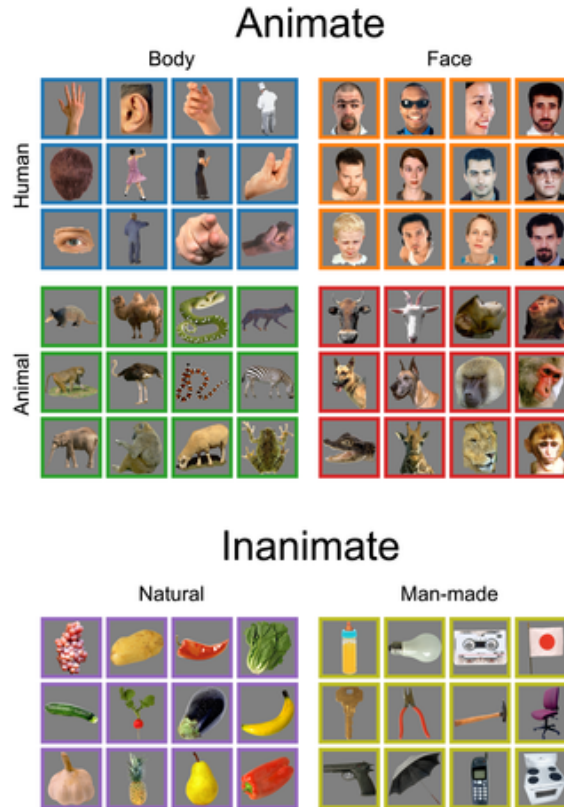
Ορισμένες μελέτες EEG και μαγνητοεγκεφαλογραφίας (MEG) έχουν διερευνήσει την επιλεκτικότητα κατηγορίας χρησιμοποιώντας Multivariate Pattern Classification. Αυτή η προσέγγιση δεν απαιτεί προεπιλογή χωρικών ή χρονικών συνιστωσών της απόκρισης του εγκεφάλου για ανάλυση, αλλά επιτρέπει ταυτόχρονα την πλήρη ανάλυση της απόκρισης, και μπορεί επιπλέον να παρέχει ένα data-driven μέσο για τον προσδιορισμό χωρικών, χρονικών, και φασματικών συνιστωσών στις οποίες βασίζεται η διάκριση κατηγορίας. Οι πρώτες μελέτες που χρησιμοποίησαν αυτήν την προσέγγιση ταξινόμησαν single-trial EEG σε φωτογραφίες προσώπων και αυτοκινήτων σε διαφορετικά επίπεδα συνοχής φάσης ως μέσο συσχέτισης νευρικών συστημάτων με συμπεριφορική διάκριση. Μεταγενέστερες μελέτες έχουν δείξει ότι έως και έξι κατηγορίες αντικειμένων μπορούν να αποκωδικοποιηθούν από πολυμεταβλητά δεδομένα EEG και MEG ήδη από 80 ms μετά την παρουσίαση ερεθίσματος.

## 3 Σύνολα Δεδομένων και Χαρακτηριστικά

### 3.1 Συμμετέχοντες και ερεθίσματα

Στο συγκεκριμένο πείραμα συμμετείχαν 10 άνθρωποι, ηλικίας 21 έως 57 ετών (διάμεση ηλικία 30,5 ετών, 3 γυναίκες, 1 αριστερόχειρας). Όλοι οι συμμετέχοντες ανέφεραν φυσιολογική έγχρωμη όραση και είτε φυσιολογική (normal) είτε corrected-to-normal όραση.

Χρησιμοποιήθηκαν 72 φωτογραφίες πραγματικών αντικειμένων ως ερεθίσματα, που ελήφθησαν από το σύνολο 92 εικόνων που έχουν χρησιμοποιηθεί σε προηγούμενες μελέτες RSA. Μειώθηκε η ποσότητα των άψυχων (Inanimate) εικόνων στο σύνολο για να διασφαλιστεί ότι κάθε κατηγορία εικόνας θα περιέχει τον ίδιο αριθμό exemplars - συγκεκριμένα, 12 εικόνες από καθεμία από τις ακόλουθες 6 κατηγορίες: Ανθρώπινο Σώμα (Human Body - HB), Ανθρώπινο Πρόσωπο (Human Face - HF), Σώμα Ζώου (Animal Body - AB), Πρόσωπο Ζώου (Animal Face - AF), Φρούτα Λαχανικά (Fruit Vegetable - FV) και Άψυχα Αντικείμενα (Inanimate Object - IO). Όπως απεικονίζεται στην Εικόνα 1, τα ερεθίσματα μπορούν πρώτα να διαχωριστούν σε Έμψυχα (Animate) και Άψυχα (Inanimate) superordinates. Οι έμψυχες εικόνες μπορούν στη συνέχεια να υποδιαιρεθούν σε 4 κατηγορίες κατά μήκος των διαστάσεων του Human ή Animal και Body ή Face, ενώ οι Άψυχες εικόνες είναι είτε Natural (FV) είτε Man-made (IO). Οι έγχρωμες εικόνες ρυθμίστηκαν σε μεσαίο γκρι φόντο χωρίς περίγραμμα, εκτεινόμενες έως  $7.0^\circ \times 6.5^\circ$  της οπτικής γωνίας.



Εικόνα 1: Set ερεθισμάτων που χρησιμοποιήθηκε στο πείραμα.

### 3.2 Πειραματικό Υπόδειγμα (Experimental Paradigm)

Κάθε συμμετέχων/ουσα καθόταν σε μια καρέκλα σε ένα σκοτεινό, ακουστικά θωρακισμένο θάλαμο κατά τη διάρκεια των πειραματικών συνεδριών: δε χρησιμοποιήθηκε ανάπαυση στο πηγούνι στο πείραμα. Η καρέκλα τοποθετήθηκε μπροστά από ένα γραφείο έτσι ώστε η μετρούμενη απόσταση θέασης από την οθόνη στο γραφείο να είναι 57 cm. Οι εικόνες παρουσιάστηκαν σε μια οθόνη υπολογιστή Dell 1905FP με μέση φωτεινότητα περίπου 100 cd/m<sup>2</sup>. Κάθε trial αποτελούταν από μία μεμονωμένη εικόνα, σε ένα γκρι φόντο ταιριαστό με το φόντο της εικόνας, που εμφανιζόταν στην οθόνη για 500 ms, ακολουθούμενη από 750 ms μιας κενής γκρι οθόνης, για ένα συνολικό ενδιάμεσο διάστημα 1.250 ms. Για να ελαχιστοποιηθούν οι κινήσεις των ματιών κατά τη διάρκεια και μεταξύ των trials, ένα λευκό fixation cross, εκτενόμενο  $0,76^\circ \times 0,76^\circ$  της οπτικής γωνίας, τοποθετήθηκε τόσο στο κέντρο κάθε εικόνας όσο και στην ίδια θέση στην κενή οθόνη που εμφανίζεται μεταξύ των παρουσιάσεων εικόνας. Τα ερεθίσματα παρουσιάστηκαν χρησιμοποιώντας το λογισμικό [Neurobehavioral Systems Presentation](#) σε τμήματα (blocks) 864 δοκιμών, όπου κάθε εικόνα εμφανίστηκε δώδεκα φορές σε τυχαία σειρά. Δόθηκαν σύντομα διαλείμματα μετά από κάθε 36 trials. Δόθηκαν μεγαλύτερα διαλείμματα μεταξύ blocks για τον έλεγχο των αντιστάσεων ηλεκτροδίων (electrode impedances). Κάθε συμμετέχων ολοκλήρωσε δύο πειραματικές συνεδρίες, καθεμία από τις οποίες περιείχε τρία blocks, σε απόσταση μεταξύ έξι

και οκτώ ημερών. Συνολικά, κάθε συμμετέχων ολοκλήρωσε 72 trials από καθεμία από τις 72 εικόνες, για συνολικά 5.184 trials ανά συμμετέχοντα.

### 3.3 Απόκτηση Δεδομένων και Προεπεξεργασία (Data Acquisition and Preprocessing)

Τα δεδομένα συλλέχθηκαν στο Κέντρο Μελέτης Γλώσσας και Πληροφοριών στο Πανεπιστήμιο του Στάνφορντ (Center for the Study of Language and Information at Stanford University). Το dense-array EEG καταγράφηκε χρησιμοποιώντας unshielded 128-channel EGI HCGSN 110 nets. Τα δεδομένα αποκτήθηκαν με vertex reference χρησιμοποιώντας τον ενισχυτή EGI Net Amps 300 και το λογισμικό απόκτησης EGI Net Station 4.4, με δειγματοληψία στα 1 kHz με εύρος 24 bits. Η αντίσταση ηλεκτροδίων στην αρχή κάθε πειραματικού block ήταν εντός αποδεκτών ορίων για αυτό το σύστημα, δηλαδή δεν ξεπερνούσε τα 80 kΩ.

Η προεπεξεργασία δεδομένων πραγματοποιήθηκε offline χρησιμοποιώντας λογισμικό [Matlab](#). Ένα high-pass fourth-order Butterworth φίλτρο αφαίρεσε περιεχόμενο συχνότητας κάτω από 1 Hz για την αφαίρεση του DC offset. Ένα low-pass eighth-order Chebyshev Type I φίλτρο αφαίρεσε συχνότητες άνω των 25 Hz πριν τα δεδομένα υποβαθμιστούν προσωρινά κατά ένα συντελεστή 16, για ένα τελικό ρυθμό δειγματοληψίας 62,5 Hz. Τα ηλεκτρόδια 1 έως 124 διατηρήθηκαν για περαιτέρω ανάλυση, όπως και τα κανάλια VEOG και HEOG για artifact removal. Τα ocular artifacts αφαιρέθηκαν από την εγγραφή EEG κάθε συμμετέχοντος, χρησιμοποιώντας τον εκτεταμένο αλγόριθμο Infomax ICA, όπως υλοποιείται στην εργαλειοθήκη Matlab EEGLAB. Τα cleaned αρχεία δεδομένων στη συνέχεια μετατράπηκαν σε average reference. Τα δεδομένα είναι χωρισμένα σε εκτελέσεις που αποτελούνται από 32-time samples (496 ms) για το κάθε ηλεκτρόδιο. Ως τελικό βήμα προεπεξεργασίας πριν από την ταξινόμηση, κάθε space-time EEG data matrix  $X_0$ , στο οποίο οι σειρές αντιπροσωπεύουν ηλεκτρόδια και οι στήλες αντιπροσωπεύουν δείγματα χρόνου τάσης, αναδιαμορφώθηκαν σε ένα trial-space matrix  $X_1$ , στο οποίο οι σειρές αντιπροσωπεύουν trials και οι στήλες περιέχουν τα χρονικά διαστήματα όλων των ηλεκτροδίων που σχετίζονται με το συγκεκριμένο trial, ενοποιημένα. Τα trial-space EEG σύνολα δεδομένων που χρησιμοποιούνται για την ταξινόμηση είναι διαθέσιμα για δημόσια λήψη από το [Stanford Digital Repository](#).

### 3.4 Dataset

Τα δεδομένα είναι χωρισμένα σε δέκα ανώνυμα dataset, ένα για κάθε συμμετέχοντα/ουσα. Κάθε ένα από αυτά περιέχει τα EEG δεδομένα και τις ετικέτες των ερεθισμάτων (εικόνων). Σε κάθε dataset υπάρχει:

- ένας δυδιάστατος πίνακας οι γραμμές του οποίου αντιστοιχούν στα trials και κάθε στήλη του οποίου προκύπτει ως η ενοποίηση των EEG δεδομένων από τα 32-time samples και τα 124 ηλεκτρόδια ( $X_{2D} = \text{Trials} \times (\text{Time-Samples} \times \text{Electrodes})$ )
- ένα τριδιάστατο πίνακα οι διαστάσεις του οποίου είναι τα trials, τα ηλεκτρόδια και τα time samples (δηλαδή δεν έχει γίνει ενοποίηση των δύο διαστάσεων όπως στον  $X_{2D}$ ) ( $X_{3D} = \text{Trials} \times \text{Time-Samples} \times \text{Electrodes}$ )
- ένα διάνυσμα μήκους T, όσο το πλήθος των trials, που περιέχει τις ετικέτες των 72 exemplars
- ένα διάνυσμα μήκους T, όσο το πλήθος των trials, που περιέχει τις ετικέτες των 6 κατηγοριών

## 4 Θεωρητικό Πλαίσιο και Μέθοδοι

### 4.1 Αλγόριθμοι ταξινόμησης

Οι αλγόριθμοι που χρησιμοποιήθηκαν για τη μείωση των διαστάσεων των δεδομένων και για την ταξινόμηση περιγράφονται παρακάτω:

- **PCA:** Η Principal Component Analysis (PCA) είναι μία μέθοδος για τη μείωση της διαστατικότητας των δεδομένων και την εξαγωγή χαρακτηριστικών. Συγκεκριμένα, συνδυάζει τα χαρακτηριστικά, έτσι ώστε

να αξιοποιηθεί η συσχέτιση μεταξύ των δεδομένων, και κρατάει μερικά μόνο από τα νέα χαρακτηριστικά, τα οποία περιέχουν παράλληλα την περισσότερη πληροφορία των δεδομένων. Η μείωση του αριθμού των χαρακτηριστικών μπορεί να έχει κάποιο αντίκτυπο στην ακρίβεια του μοντέλου που θα χρησιμοποιηθεί για τα νέα δεδομένα, ωστόσο η ανάλυση δεδομένων γίνεται πιο εύκολη και πιο γρήγορη. Έχοντας κάποια σημεία τοποθετημένα σε  $k$  διαστάσεις, γίνεται προβολή στο διάνυσμα εκείνο που ελαχιστοποιεί τη μέση τετραγωνική απόσταση από τα σημεία πάνω στην ευθεία που ορίζει. Το διάνυσμα αυτό διατηρεί τη μέγιστη διακύμανση και ονομάζεται πρώτη κύρια συνιστώσα. Το επόμενο διάνυσμα επιλέγεται με παρόμοιο τρόπο κι όντας ορθογώνιο στην πρώτη κύρια συνιστώσα. Έτσι προκύπτουν τα διανύσματα που ορίζουν ορθοκανονικές κύριες συνιστώσες που μετασχηματίζουν τα δεδομένα με  $k$  συνταγμένες σε νέα δεδομένα με  $k$  συντεταγμένες  $a_i$  που αποτελούν τις Κύριες Συνιστώσες (Principal Components). Επιλέγοντας τις σημαντικότερες από αυτές τις συνιστώσες προκύπτει μία εκτίμηση των αρχικών δεδομένων με μικρότερο αριθμό συνιστωσών. Η συνολική διασπορά του σφάλματος υπολογίζεται μέσω των ιδιοτιμών, των αντίστοιχων ιδιοδιανυσμάτων. Δηλαδή όσο πιο μεγάλη είναι η τιμή ιδιοτιμής τόσο μεγαλύτερη διασπορά εκφράζει. Συνεπώς, ο αλγόριθμος επιλέγει να κρατήσει τις μεγαλύτερες ιδιοτιμές.

Ο αλγόριθμος PCA μπορεί να εφαρμοστεί είτε με τη μέθοδο covariance είτε με τη μέθοδο Singular Value Decomposition (SVD), την οποία χρησιμοποιήσαμε. Η μέθοδος SVD μετατρέπει τον αρχικό πίνακα δεδομένων  $Q$  σε ένα γινόμενο πινάκων:  $X = U\Sigma V^T$ , όπου ο πίνακας  $\Sigma$  είναι ένας διαγώνιος πίνακας με singular values (σε αντιστοιχία με τις ιδιοτιμές), ενώ ο πίνακας  $V$  περιέχει τα singular vectors (σε αντιστοιχία με τα ιδιοδιανύσματα). Συνεπώς, τα νέα δεδομένα προκύπτουν πολλαπλασιάζοντας τον πίνακα  $Q$  με τον πίνακα  $V$ .

- **LDA:** Η μέθοδος Linear Discriminant Analysis (LDA) είναι μία μέθοδος που χρησιμοποιείται στη μηχανική μάθηση για να βρούμε έναν γραμμικό συνδυασμό των χαρακτηριστικών που διαχωρίζει δύο ή περισσότερες κλάσεις. Ο συνδυασμός που προκύπτει μπορεί να χρησιμοποιηθεί ως ένας γραμμικός ταξινομητής ή απλά για τη μείωση της διαστατικότητας των δεδομένων. Η μέθοδος LDA έχει κάποιες ομοιότητες με τη μέθοδο PCA, ωστόσο η βασική διαφορά τους είναι ότι η LDA προσπαθεί να μοντελοποιήσει τη διαφορά μεταξύ των δεδομένων που ανήκουν σε διαφορετικές κλάσεις. Για δύο κλάσεις, η LDA προσεγγίζει το πρόβλημα θεωρώντας πως η υπο συνθήκη πιθανότητες  $p(x|y = 0)$  και  $p(x|y = 1)$  ακολουθούν κανονική κατανομή. Στη συνέχεια, δημιουργεί ένα νέο άξονα στον οποίο προβάλλει τα δεδομένα. Ο σκοπός είναι να βρεθεί ο άξονας με τον οποίο μεγιστοποιείται η απόσταση μεταξύ των μέσων όρων των δύο κλάσεων και που ελαχιστοποιεί τη διασπορά των δεδομένων κάθε κατηγορίας. Η λογική αυτή γενικεύεται για μεγαλύτερο αριθμό κλάσεων και χαρακτηριστικών.
- **SVM:** Τα Support-Vector Machines (SVM) είναι μοντέλα επιβλεπόμενης μάθησης που χρησιμοποιούνται για προβλήματα ταξινόμησης και παλινδρόμησης. Συγκεκριμένα, ένα SVM κατασκευάζει ένα υπερεπίπεδο σε έναν υψηλό χώρο διαστάσεων, με σκοπό να διαχωρίσει τα δεδομένα στις διάφορες κλάσεις. Ένας καλός διαχωρισμός επιτυγχάνεται από το υπερεπίπεδο που έχει τη μεγαλύτερη απόσταση από τα πιο κοντινά σημεία από όλες τις κλάσεις (maximum margin). Όσο μεγαλύτερη είναι αυτή η απόσταση τόσο μικρότερο είναι το σφάλμα γενίκευσης του ταξινομητή. Ωστόσο, πολλές φορές τα δεδομένα δεν είναι γραμμικώς διαχωρίσιμα στον χώρο διαστάσεων που βρίσκονται. Για αυτό το λόγο, χρησιμοποιούνται κάποιες συναρτήσεις πυρήνα (kernel) οι οποίες δίνουν τη δυνατότητα να λειτουργούμε σε έναν χώρο υψηλών διαστάσεων, χωρίς να χρειάζεται να υπολογιστούν οι αντίστοιχες συντεταγμένες των δεδομένων σε αυτό το χώρο, αλλά υπολογίζονται τα εσωτερικά γινόμενα μεταξύ των απεικονίσεων όλων των ζευγών δεδομένων. Δηλαδή, πραγματοποιείται υπολογισμός των σχέσεων των δεδομένων σε υψηλές διαστάσεις, χωρίς να μεταφερθούν πραγματικά τα δεδομένα σε υψηλότερη διάσταση. Με αυτόν τον τρόπο κάθε γραμμικό μοντέλο μπορεί να μετατραπεί σε μή γραμμικό. Η συνάρτηση πυρήνα που χρησιμοποιήσαμε είναι η RBF kernel.

## 4.2 Μέθοδοι Deep Learning

Είναι γεγονός πως το Deep Learning έχει καταφέρει, σε πολλές εφαρμογές, να ξεπεράσει τις κλασσικές μεθόδους μηχανικής μάθησης και να θεωρείται στις περισσότερες από αυτές State Of The Art. Αυτό είχε ως συνέπεια, να εφαρμόσουμε και εμείς κάποια κλασσικά νευρωνικά δίκτυα, όπως τα απλά Deep Feedforward Neural Nets (DFNN) ή τα Convolutional Neural Networks (CNN).

- **DFNN:** Τα Deep FeedForward Neural Networks (DFNN), ή αλλιώς Multilayer Perceptrons (MLP), είναι τα βασικά μοντέλα βαθιάς μηχανικής μάθησης, καθώς είναι η βάση όλων των νευρωνικών δικτύων. Αυτά τα μοντέλα ονομάζονται feedforward, γιατί η πληροφορία ρέει σε μία ευθύγραμμη κατεύθυνση, δηλαδή ρέει μέσω μιας συνάρτησης που ορίζεται από ένα  $x$ , μέσω ενδιάμεσων υπολογισμών για τον υπολογισμό της  $f$  και τελικά καταλήγει στον υπολογισμό της εξόδου  $y$ . Συνεπώς, η εκπαίδευση των συγκεκριμένων νευρωνικών δικτύων είναι αρκετά γρήγορη. Όταν προστίθενται feedback συνδέσεις από το τελευταίο κρυφό επίπεδο προς το πρώτο κρυφό επίπεδο, τότε προκύπτει ένα Recurrent Neural Network (RNN). Συγκεκριμένα, ένα DFNN αποτελείται από τρία ή περισσότερα επίπεδα νευρώνων, το επίπεδο εισόδου, το επίπεδο εξόδου και ένα ή περισσότερα κρυφά επίπεδα. Κάθε νευρώνας κάθε επιπέδου συνδέεται με ένα αντίστοιχο βάρος  $w_{ij}$  με κάθε νευρώνα του επόμενου επιπέδου, ενώ δεν υπάρχουν συνδέσεις μεταξύ νευρώνων του ίδιου επιπέδου ή συνδέσεις μεταξύ νευρώνων που δεν ανήκουν σε διαδοχικά επίπεδα. Οι νευρώνες των κρυφών επιπέδων χρησιμοποιούν μία μη γραμμική συνάρτηση ενεργοποίησης, σε μία προσπάθεια μοντελοποίησης της συμπεριφοράς των βιολογικών νευρώνων. Οι πιο συνηθισμένες συναρτήσεις ενεργοποίησης που χρησιμοποιούνται είναι η sigmoid και η rectifier linear unit (ReLU). Επιπλέον, τα DFNN χαρακτηρίζονται από το παγκόσμιο θεώρημα προσέγγισης. Με απλά λόγια, ένα DFNN με γραμμικό επίπεδο εξόδου και με κατάλληλο αριθμό κρυφών επιπέδων νευρώνων με μία μη γραμμική συνάρτηση ενεργοποίησης μπορεί να προσεγγίσει οποιαδήποτε συνάρτηση. Ωστόσο, αυτό το θεώρημα είναι σημαντικό κυρίως για θεωρητικούς λόγους, καθώς είναι πολύ δύσκολο να βρεθεί η κατάλληλη αρχιτεκτονική που θα προσεγγίσει μία συνάρτηση.
- **CNN:** Από τα πιο δημοφιλή και ισχυρά είδη νευρωνικών δικτύων είναι τα Convolutional Neural Network (CNNs), τα οποία παρουσιάστηκαν από τον LeCun. Ειδικεύονται στο να επεξεργάζονται δεδομένα που παρουσιάζουν μια τοπολογία μέσα σε ένα grid ή κάποια patterns. Τέτοια παραδείγματα είναι τα 1-D grid, που αφορούν χρονοσειρές, και τα 2-D grid, που αφορούν κυρίως εικόνες. Ονομάζονται convolutional καθώς η πράξη που τα διαφοροποιεί από τα άλλα είδη νευρωνικών είναι η πράξη της συνέλιξης (convolution). Ένα CNN αποτελείται από ένα επίπεδο εισόδου, ένα επίπεδο εξόδου και πολλαπλά κρυφά επίπεδα. Τα κρυφά επίπεδα ενός CNN είναι συνήθως συνελκτικά, δηλαδή χρησιμοποιούν τη πράξη της συνέλιξης έστω και σε ένα layer αντί για τον κλασικό πολλαπλασιασμό πινάκων. Η συνάρτηση ενεργοποίησης είναι συνήθως ένα επίπεδο ReLU, ενώ συνήθως ακολουθείται από κάποιο επίπεδο ομαδοποίησης (pooling) και κάποιο πλήρως συνδεδεμένο επίπεδο (fully connected layer). Τα επίπεδα ομαδοποίησης μειώνουν τις διαστάσεις των δεδομένων συνδυάζοντας τις εξόδους των νευρώνων από ένα επίπεδο σε έναν νευρώνα στο επόμενο επίπεδο. Το τοπικό pooling συνδυάζει μικρές ομάδες νευρώνων, ενώ το ολικό pooling συνδυάζει όλους τους νευρώνες του προηγούμενου επιπέδου. Τα πλήρως συνδεδεμένα επίπεδα συνδέουν κάθε νευρώνα ενός επιπέδου σε κάθε νευρώνα του επόμενου επιπέδου.
- **Transfer Learning:** Το Transfer Learning είναι μία μέθοδος κατά την οποία ένα μοντέλο που έχει εκπαιδευτεί για ένα πρόβλημα χρησιμοποιείται ως σημείο έναρξης για ένα άλλο μοντέλο, για να λύσουμε ένα άλλο πρόβλημα. Δηλαδή, σε Pre-Trained Models, προσθέτουμε λίγα ακόμα επίπεδα για να προσαρμόσουμε το νευρωνικό προς το δικό μας πρόβλημα και στη συνέχεια εφαρμόζουμε Fine Tuning. Το Transfer Learning είναι μία τεχνική βελτιστοποίησης, που μας βοηθάει να γλιτώσουμε χρόνο ή να έχουμε καλύτερη απόδοση. Με την τεχνική Fine Tuning δεν προσθέτουμε απλά τα τελικά επίπεδα, αλλά επανεκπαιδεύουμε επιλεκτικά κάποια από τα προηγούμενα επίπεδα. Οπότε, με αυτόν τον τρόπο μπορούμε να παγώσουμε κάποια επίπεδα (τα βάρη) και να επανεκπαιδεύσουμε τα υπόλοιπα με βάση τις ανάγκες μας. Ως αποτέλεσμα αυτό μας βοηθάει να πετύχουμε καλύτερη απόδοση με λιγότερο χρόνο εκπαίδευσης. Μερικά Pre-Trained μοντέλα είναι τα VGG-16, ResNet-50, Word2Vec και GloVe.

#### 4.3 Μέθοδοι αξιολόγησης ταξινομητών

Η αξιολόγηση των ταξινομητών πραγματοποιήθηκε με τη χρήση της μεθόδου cross-validation και των μεγεθών της ακρίβειας και Confusion Matrix. Ακολουθεί η ερμηνεία των παραπάνω μεθόδων:

- **Cross-validation:** Η μέθοδος αυτή χρησιμοποιείται για την αξιολόγηση ενός μοντέλου ταξινόμησης με σκοπό την εκτίμηση της ικανότητας του μοντέλου να προβλέπει νέα δεδομένα και να γενικεύει, ώστε να αποφευχθούν προβλήματα, όπως είναι η υπερεκπαίδευση (overfitting). Ένας γύρος του cross-validation περιλαμβάνει το διαχωρισμού ενός δείγματος δεδομένων σε δύο υποσύνολα, όπου το ένα

υποσύνολο συμμετέχει στην εκπαίδευση του μοντέλου και το άλλο στην αξιολόγησή του. Στις περισσότερες μεθόδους τύπου cross-validation πραγματοποιούνται πολλοί γύροι κάθε φορά με τη χρήση διαφορετικών υποσυνόλων δεδομένων, ενώ τα τελικά αποτελέσματα συνδυάζονται ώστε να πάρουμε μία εκτίμηση της προβλεπτικής ικανότητας του μοντέλου. Στη συγκεκριμένη έρευνα χρησιμοποιήθηκε η μέθοδος 10-fold cross-validation. Σε αυτή τη μέθοδο το αρχικό σύνολο δεδομένων χωρίζεται σε 10 ίσα υποσύνολα δεδομένων. Από αυτά τα 10 υποσύνολα, το ένα υποσύνολο θεωρείται το σύνολο αξιολόγησης του μοντέλου, ενώ τα υπόλοιπα 9 χρησιμοποιούνται για την εκπαίδευση του μοντέλου. Έστερα, η διαδικασία επαναλαμβάνεται συνολικά 10 φορές, όπου κάθε ένα υποσύνολο από τα 10 χρησιμοποιείται ακριβώς μία φορά ως σύνολο αξιολόγησης. Το τελικό αποτέλεσμα προκύπτει από τον μέσο όσο των 10 αποτελεσμάτων. Το πλεονέκτημα αυτής της μεθόδου είναι ότι όλες οι παρατηρήσεις χρησιμοποιούνται και για την εκπαίδευση και για την επαλήθευση του μοντέλου, ενώ κάθε παρατήρηση χρησιμοποιείται για την επαλήθευση ακριβώς μία φορά.

- **Accuracy (Ακρίβεια):** Το μέγεθος αυτό ισούται με το πηλίκο του πλήθους των συνολικών σωστών προβλέψεων του ταξινομητή προς το συνολικό πλήθος προβλέψεων. Δηλαδή:

$$Accuracy = \frac{\text{Number of Correct Predictions}}{\text{Total Number of Predictions}}$$

- **Confusion Matrix (Πίνακας Σύγχυσης):** Ο πίνακας σύγχυσης είναι ένας πίνακας  $C$ , τέτοιος ώστε το  $C_{ij}$  να είναι ίσο με τα δείγματα που ενώ ανήκουν στην κατηγορία  $i$  ταξινομήθηκαν στην κατηγορία  $j$ . Τα στοιχεία της διαγωνίου έχουν ταξινομηθεί σωστά (True Positive) για την κάθε κλάση. Για κάθε κλάση  $i$  τα στοιχεία της γραμμής  $i$ , που είναι τα στοιχεία της κλάσης, εκτός της διαγωνίου έχουν ταξινομηθεί λανθασμένα σε άλλες κλάσεις (False Negative), ενώ τα στοιχεία της στήλης  $j$  εκτός της διαγωνίου είναι τα στοιχεία των υπολοίπων κλάσεων που ταξινομήθηκαν λανθασμένα στην κλάση  $i$  (False Positive). Ουσιαστικά, ο πίνακας σύγχυσης είναι ένας τρόπος εντοπισμού του ενδεχομένου το σύστημα να μπερδεύει κάποιες κλάσεις μεταξύ τους.

#### 4.4 Ταξινόμηση για κάθε συμμετέχων (Single-Trial Classification)

Σε μία επιβλεπόμενη ταξινόμηση, ένα μοντέλο εκπαιδεύεται από ένα σύνολο παρατηρήσεων που ανήκουν σε κάποιες κλάσεις και στη συνέχεια χρησιμοποιείται για την πρόβλεψη των κλάσεων από παρατηρήσεις δοκιμής. Κάθε παρατήρηση αναπαριστάται από ένα σύνολο χαρακτηριστικών. Στη συγκεκριμένη έρευνα, μία παρατήρηση καθορίζεται ως η EEG απόκριση σχετικά με μία πειραματική δοκιμή, ενώ το διάνυσμα των χαρακτηριστικών που περιγράφει την κάθε παρατήρηση είναι το αντίστοιχο σύνολο τάσεων από ηλεκτρόδια και χρονικών σημείων ενδιαφέροντος. Μία κλάση είναι η περιγραφή του ερεθίσματος που χρησιμοποιήθηκε στην αντίστοιχη δοκιμή, και μπορεί να είναι είτε το όνομα μίας εικόνας ή μία κατηγορία εικόνων. Ωστόσο, οι διαστάσεις του διανύσματος των χαρακτηριστικών είναι, για ολόκληρο το σύνολο δεδομένων, 124 ηλεκτρόδια επί 32 χρονικά δείγματα, δηλαδή 3,968 χαρακτηριστικά. Με ένα τόσο μεγάλης διάστασης διάνυσμα χαρακτηριστικών, είναι λογικό το μοντέλο ταξινόμησης να εκπαιδευτεί σε πληροφορίες που δεν είναι σημαντικές. Για αυτό το λόγο, χρησιμοποιείται η μέθοδος PCA, με τη χρήση της μεθόδου SVD. Ο ακριβής αριθμός κύριων συνιστωσών που χρησιμοποιήθηκε στην ταξινόμηση καθορίστηκε μέσω της μεθόδου cross-validation.

Όλες οι ταξινομήσεις έγιναν αρχικά ξεχωριστά για τον κάθε συμμετέχων με τη χρήση της μεθόδου LDA. Για το σκοπό αυτό χρησιμοποιήθηκε ο πίνακας  $X_{2D}$  των δεδομένων. Προκειμένου να έχουμε μία αμερόληπτη εκτίμηση του ποσοστού επιτυχίας της ταξινόμησης, χρησιμοποιήθηκε η μέθοδος cross-validation, όπου τα δεδομένα αρχικά ανακατεύτηκαν και χωρίστηκαν σε δέκα ομάδες (folds). Σε κάθε fold, οι εννέα αντίστοιχες ομάδες, που λειτουργούσαν ως δεδομένα εκπαίδευσης, υποβλήθηκαν σε ένα εμφωλευμένο 10-fold cross-validation, όπου καθοριζόταν ο αριθμός των κύριων συνιστωσών μέσω PCA. Σημειώνουμε, ότι η μέθοδος SVD πραγματοποιήθηκε μία φορά εκτός των cross-validation καθώς είναι μία υπολογιστικά ακριβή διεργασία. Η επιλογή του βέλτιστου αριθμού συνιστωσών  $k$  κυμαινόταν μεταξύ 3 και  $\min(200, K)$ , όπου  $K$  είναι το μήκος του διανύσματος χαρακτηριστικών. Σημειώνουμε ότι η έκφραση  $\min(200, K)$  είναι απαραίτητη, καθώς η ίδια συνάρτηση χρησιμοποιήθηκε και σε ταξινομήσεις που δεν περιλάμβαναν ολόκληρο το σύνολο δεδομένων και που το διάνυσμα χαρακτηριστικών ήταν μικρότερο από 200. Προκειμένου να βρούμε το βέλτιστο  $k$ , σε κάθε fold του εμφωλευμένου cross-validation, εκπαιδεύουμε ένα μοντέλο LDA για όλα τα πιθανά  $k$ , αφού έχουμε μειώσει τις διαστάσεις των αντίστοιχων δεδομένων εκπαίδευσης σε  $k$ . Επιλέγουμε να κρατήσουμε το  $k$  που δίνει το μεγαλύτερο ποσοστό επιτυχίας στην ομάδα επαλήθευσης. Οπότε, από το εμφωλευμένο cross-validation προκύπτουν 10 πιθανά βέλτιστα  $k$ , από τα οποία πάλι επιλέγουμε εκείνο που δίνει το μεγαλύτερο



ποσοστό επιτυχίας. Στη συνέχεια, με βάση αυτό το  $k$  μειώνουμε τις διαστάσεις των δεδομένων εκπαίδευσης (του εξωτερικού cross-validation) και εκπαιδεύουμε ένα μοντέλο LDA. Αφότου ολοκληρωθούν όλα τα folds, η συνάρτηση επιστρέφει τη μέση τιμή όλων των ποσοστών επιτυχίας (του εξωτερικού cross-validation) και τον τελικό confusion matrix, στον οποίο θα αναφερθούμε παρακάτω. Για να συγκρίνουμε τα αποτελέσματα που δίνει η μέθοδος LDA, επαναλάβουμε ακριβώς την ίδια διαδικασία με παραπάνω με τη χρήση της μεθόδου SVM με πυρήνα RBF.

Εκτός από την ταξινόμηση ολόκληρου του συνόλου δεδομένων, εκτελέσαμε ταξινομήσεις σε χωρικά (spatial) και χρονικά (temporal) υποσύνολα του συνόλου δεδομένων, ώστε να αποκτήσουμε μία πιο βαθειά επίγνωση της κατηγορικής αναπαράστασης αντικειμένων. Για το σκοπό αυτό χρησιμοποιήθηκε ο πίνακας  $X_{3D}$  των δεδομένων. Για τη χωρική ανάλυση, πραγματοποιήθηκαν ανεξάρτητες ταξινομήσεις χρησιμοποιώντας όλα τα χρονικά δείγματα από ένα ηλεκτρόδιο κάθε φορά. Τα αποτελέσματα της διαδικασίας αυτής μπορούν να μας δείξουν ποια ηλεκτρόδια περιέχουν περισσότερο σημαντικές πληροφορίες για την ταξινόμηση. Όσον αφορά τη χρονική ανάλυση, εκτελέσαμε ξεχωριστές ταξινομήσεις σε επικαλυπτόμενα συνεχόμενα χρονικά υποσύνολα. Συγκεκριμένα, πήραμε δείγματα χρόνου περίπου 80ms (5 χρονικά δείγματα) και κάθε φορά προχωρούσαμε την ανάλυση κατά περίπου 48ms (3 χρονικά δείγματα). Κάθε ταξινόμηση συνδυάζει τα δεδομένα από όλα τα 124 ηλεκτρόδια, με αποτέλεσμα να μπορούμε να μελετήσουμε ποια χρονικά παράθυρα δίνουν καλύτερα ποσοστά επιτυχίας. Τέλος, πραγματοποιήθηκαν ταξινομήσεις για κάθε ηλεκτρόδιο ξεχωριστά σε κάθε χρονικό παράθυρο.

Σε κάθε ταξινόμηση παράγουμε έναν confusion matrix. Συνεπώς, πρέπει να συνδυάσουμε όλους τους 10 confusion matrices που προκύπτουν από το εξωτερικό cross-validation. Αυτό το πετυχαίνουμε αθροίζοντας τους όλους μαζί. Στη συνέχεια, επειδή το σύνολο δεδομένων περιλαμβάνει ένα ισορροπημένο αριθμό παρατηρήσεων από κάθε κλάση, διαιρούμε κάθε στοιχείο του confusion matrix με το άθροισμα της γραμμής που βρίσκεται αυτό το στοιχείο, ώστε το άθροισμα της κάθε γραμμής να ισούται με ένα. Αυτή τη μέθοδο τη χρησιμοποιήσαμε σε όλους τους confusion matrices που δημιουργήσαμε, ενώ τη χρησιμοποιήσαμε και για να συνδυάσουμε τα αποτελέσματα περισσότερων σεμιντεχόντων. Επιπλέον, η ακρίβεια του ταξινομητή, μέσω αυτού του κανονικοποιημένου confusion matrix, ορίζεται ως ο μέσος όρος των στοιχείων της διαγωνίου του confusion matrix.

#### 4.5 Πολυδιάστατη Κλιμάκωση και Ομαδοποίηση (Multidimensional Scaling and Clustering)

Η Representational Similarity Analysis (RSA) είναι μια πολυμεταβλητή τεχνική με την οποία εξάγεται πληροφορία για την κατανομή μοτίβων αναπαράστασης στον εγκέφαλο. Βρίσκει εφαρμογές σε διάφορους τύπους δεδομένων νευροαπεικόνισης και ταιριάζει καλά σε πειραματικούς σχεδιασμούς όπου τα αντικείμενα μπορούν να συσχετιστούν μεταξύ τους. Σε γενικές γραμμές, η RSA αφορά το σχεδιασμό ενός πειραματικού task με διακριτές εκτελέσεις και τον εντοπισμό συσχετίσεων μεταξύ ζευγών εκτελέσεων που προέρχονται από διαφορετικές συνθήκες, μέσω μιας μετρικής εγγύτητας. Η RSA έχει φανεί πολύτιμη στην κατανόηση της μνήμης καθώς έχει επιτρέψει τους ερευνητές να θέσουν ερωτήματα για το πώς αναπαρίσταται η πληροφορία όταν μαθαίνεται ή όταν γίνεται ανάκλησή της.

Το γεγονός ότι οι αποκρίσεις από τις EEG/MEG καταγραφές περιέχουν πληροφορία για την κατηγορία των αντικειμένων οδήγησε σε μια λεπτομερή ανάλυση της δομής αναπαράστασης (στον εγκέφαλο) των κατηγοριών αντικειμένων. Η ιδέα πίσω από τη δομή της αναπαράστασης, όπως νοηματοδοτείται και χρησιμοποιείται στο RSA, είναι ότι οι αποκρίσεις σε διάφορα ερεθίσματα μπορούν να συγκριθούν αξιοποιώντας τις αποστάσεις μεταξύ τους. Κατά τη διάρκεια του πειράματος μετράται η εγκεφαλική δραστηριότητα του υποκειμένου ενώ αυτό εκτίθεται σε ένα πλήθος  $N$  πειραματικών συνθηκών, εν προκειμένω ερεθίσματα εικόνων. Για κάθε περιοχή του εγκεφάλου που ενδιαφέρει τη μελέτη, εκτιμάται ένα μοτίβο δραστηριότητας για κάθε μία από τις πειραματικές συνθήκες. Για κάθε ζεύγος μοτίβων δραστηριότητας υπολογίζεται η ανομοιότητα μέσω μιας μετρικής εγγύτητας και εισάγεται σε έναν πίνακα που ονομάζεται RDM. Ο πίνακας αυτός επομένως προκύπτει συμμετρικός με μηδενική διαγώνιο, και ουσιαστικά περιγράφει τη γεωμετρία της αναπαράστασης χρησιμεύοντας μεταξύ άλλων στη σύγκριση διαφορετικών περιοχών του εγκεφάλου.

Υπάρχουν διάφοροι τρόποι κατασκευής του RDM. Στη συγκεκριμένη έρευνα ακολουθήθηκε η εξής διαδικασία:

- Υπολογισμός του confusion matrix από την εφαρμογή των ταξινομητών LDA και SVM
- Διπλή κανονικοποίηση του CM, αρχικά διαιρώντας κάθε στοιχείο με το άθροισμα των στοιχείων της



σειράς του πίνακα,  $C_{ij} = \frac{C_{ij}}{\sum_i C_{ij}}$ , και σε δεύτερη φάση διαίρεση του κάθε στοιχείου με το αντίστοιχο στοιχείο της διαγωνίου,  $C_{ij} = \frac{C_{ij}}{C_{ii}}$


- Υπολογισμός του πίνακα  $S$  με τους γεωμετρικούς μέσους των στοιχείων του CM και του αντιστρόφου του,  $CM^T$ , δηλαδή  $S = \sqrt{CM \times CM^T}$ , κατά στοιχείο
- Υπολογισμός του  $S_- = 1 - S$  και του  $D$  ως ο κάτω τριγωνικός πίνακας του  $S_-$ ,  $D = \mathcal{L}(1 - S)$ .

Στη συνέχεια έγινε οπτικοποίηση των αποτελεσμάτων με δύο τρόπους: (α) εφαρμογή Classical Multidimensional Scaling (MDS) [5] στον πίνακα  $S_-$ , μια μέθοδος που μετέτρεψε κάθε απόσταση σε σημεία στο διδιάστατο χώρο κάνοντας την αντίστοιχη μείωση διαστάσεων με προβολή στα διανύσματα που διατηρούν τη μεγαλύτερη διακύμανση, (β) δημιουργία δενδρογράμματος με ιεραρχική συσταδοποίηση (Hierarchical Clustering).

#### 4.6 Ταξινόμηση με τη χρήση Deep Learning

Σε αυτήν την ενότητα περιγράφουμε τον τρόπο με τον οποίο χρησιμοποιήσαμε τις μεθόδους Deep Learning στο σύνολο δεδομένων που χρησιμοποιήσαμε.

- **DFNN:** Πειραματιστήκαμε να συνδυάσουμε τα DFNN με το PCA, για binary classification μεταξύ των κατηγοριών Human Faces και Inanimate Objects. Ειδικότερα, με την εύρεση του optimal  $k$  μέσω του Nested Cross Validation, που περιγράψαμε προηγουμένως, εφαρμόσαμε Dimensionality Reduction στον πίνακα  $X_{2D}$ . Στη συνέχεια, δημιουργήσαμε ένα νευρωνικό δίκτυο με είσοδο το optimal  $k$  και 6 επίπεδα με διαστάσεις 160, 140, 120, 64, 32. Το τελευταίο επίπεδο έχει 1 νευρώνα, λόγω του ότι είχαμε Binary Classification. Επίσης, έχει γίνει χρήση της τεχνικής του Regularization, για να αποφευχθεί το Overfitting. Το συγκεκριμένο είδος νευρωνικού παρουσίασε αρκετά καλά αποτελέσματα στο binary classification και γρήγορα, αλλά υστερούσε στις περισσότερες κλάσεις.
- **CNN:** Χρησιμοποιήσαμε τα CNN ως 2-D grids. Αυτό αποφασίστηκε, καθώς φανταστήκαμε τα δεδομένα μας σαν εικόνες. Περαιτέρω, μπορούμε να δούμε κάθε trial ως μια 124x32 εικόνα και συγκεκριμένα ως ένα heatmap. Οι διαστάσεις καθορίζονται από τον αριθμό των ηλεκτροδίων που είναι 124 και από τον αριθμό των time samples ( $N = 32$ ). Μια τέτοια εικόνα φαίνεται για ένα πείραμα παρακάτω.



Εικόνα 2

Δοκιμάσαμε διάφορες αρχιτεκτονικές, όπως με ένα convolutional layer αλλά και πιο βαθιά συνελκτικά δίκτυα με 5 convolutional layers. Το απλό CNN περιλαμβάνει 32 φίλτρα με μέγεθος πυρήνα 3 το κάθε ένα και ακολουθεί με ένα επίπεδο flatten και ολοκληρώνεται με ένα Dense layer μεγέθους 128 και με output layer το μέγεθος των κλάσεων. Ενώ το βαθύ συνελκτικό δίκτυο, περιλαμβάνει 2 συνελκτικά επίπεδα με 8 φίλτρα και μέγεθος πυρήνα 3 στο κάθε ένα. Ακολουθεί, η διαδικασία max pooling και μετά ξανά 2 συνελκτικά επίπεδα με 16 επίπεδα το κάθε ένα και μέγεθος πυρήνα 2 το κάθε ένα. Το βαθύ CNN ολοκληρώνεται με ένα τελευταίο συνελκτικό επίπεδο με 64 φίλτρα και μέγεθος πυρήνα 3. Έπειτα ακολουθεί ένα layer που κάνει Flatten τις εξόδους του προηγούμενου επιπέδου και στη συνέχεια τοποθετούμε 3 dense layers μεγέθους 32, 16 και αριθμό κλάσεων. Αυτό έγινε, ώστε να δούμε αν έχουμε κάποια αισθητή διαφορά στην απόδοση με ένα πιο μεγάλο νευρωνικό δίκτυο για να δούμε

αν μπορεί να αποκωδικοποιήσει κάποιο pattern στην εικόνα. Τα συγκεκριμένα δίκτυα δοκιμάστηκαν και σε binary classification όπως τα DFNN και σε multiclass πρόβλημα με 6, 12 και 72 κλάσεις.


- **Transfer Learning:**

Το pre-trained νευρωνικό δίκτυο που δοκιμάσαμε να προσαρμόσουμε με fine tuning ήταν το το VGG16 net. Σκοπός μας ήταν να δούμε αν μπορεί να παρουσιάσει κάποια καλύτερη ακρίβεια από τα προηγούμενα νευρωνικά δίκτυα που δοκιμάσαμε και να δούμε πώς ένα τέτοιο σύνθετο και πολυδοκιμασμένο μοντέλο μπορεί να αποδώσει στις ανάγκες μας.

## 5 Πειράματα/Αποτελέσματα

### 5.1 Category-Level Ταξινομήσεις


Αρχικά, εκτελέσαμε ταξινομήσεις σε κατηγορικό επίπεδο για όλες τις κλάσεις. Αφότου πήραμε τα αποτελέσματα για τους 5 πρώτους συμμετέχοντες, πήραμε τη μέση τιμή της ακρίβειας του ταξινομητή μας με τη χρήση του LDA. Η ακρίβεια ήταν 37.46%, ενώ η αντίστοιχη ακρίβεια της έρευνας ήταν 40.68%. Το CM, το διάγραμμα MDS και το δενδρόγραμμα, που λάβαμε φαίνονται στις παρακάτω εικόνες. Όπως παρατηρούμε από το CM, τη μεγαλύτερη τιμή στην κάθε γραμμή την έχουμε στη διαγώνιο. Σημειώνουμε ότι τα ποσοστά της διαγωνίου αντιστοιχούν στα ποσοστά σωστής ταξινόμησης της κάθε κατηγορίας, ενώ οι γραμμές αναπαριστούν τις πραγματικές κατηγορίες και οι στήλες τις προβλεπόμενες. Ακόμα η πιο επιτυχημένη ταξινόμηση πραγματοποιείται στην κατηγορία Human Face (HF) με 61.93%, ενώ σε όλες τις υπόλοιπες κατηγορίες το ποσοστό δεν ξεπερνάει το 38%. Μάλιστα, βλέπουμε ότι ο ταξινομητής μπερδεύεται περισσότερο στην κατηγορία Fruit Vegetable (FV) με ποσοστό σωστής πρόβλεψης μόλις 22.95%.




Εικόνα 3: Category-Level CM.

Με βάση αυτόν το CM, φτιάξαμε το διάγραμμα MDS οπτικοποιώντας τα αποτελέσματα που πήραμε από τη μέθοδο RSA. Το διάγραμμα MDS δείχνει τη διαχωριστικότητα των κατηγοριών κατά μήκος της πρώτης και της δεύτερης κύριας συνιστώσας (άξονας X και Y αντίστοιχα). Παρατηρούμε ότι το HF διαχωρίζεται αρκετά από τις υπόλοιπες κατηγορίες κατά μήκος και των δύο αξόνων. Η FV διακρίνεται από τις υπόλοιπες κατά μήκος του X-άξονα ωστόσο βρίσκεται κοντά σε τρεις από τις υπόλοιπες κατηγορίες (IO, AB, AF) στον Y-άξονα. Το αντίστροφο ακριβώς συμβαίνει για την κατηγορία Human Body (HB), δηλαδή διαχωρίζεται στο Y-άξονα από τις υπόλοιπες αλλά βρίσκεται κοντά με άλλες τρεις (IO, AB, AF) στον X-άξονα. Τέλος, οι κατηγορίες Inanimate Object (IO), Animal Body (AB) και Animal Face (AF) βρίσκονται σε εγγύτητα κατά μήκος και των δύο αξόνων. Στα αντίστοιχα αποτελέσματα της έρευνας οι κατηγορίες παρουσίασαν εν γένει

μεγαλύτερη εγγύτητα. Πιο συγκεκριμένα, οι κατηγορίες HB και AB είναι πολύ κοντά μεταξύ τους, όπως και οι κατηγορίες FV και IO, ενώ η HF ξεχωρίζει εμφανώς μόνο κατά μήκος του Χ-άξονα. Στο δένδρογραμμα βλέπουμε την ιεραρχική δομή των κατηγοριών. Αρχικά διαχωρίζεται η κατηγορία FV από τις υπόλοιπες και στη συνέχεια η IO. Έπειτα, έχουμε ένα διαχωρισμό σε δύο ομάδες. Η πρώτη ομάδα αποτελείται από τις κατηγορίες HB και HF, ενώ η δεύτερη από τις AB και AF. Τα αποτελέσματα αυτά συμφωνούν με το διάγραμμα MDS.




Εικόνα 4: Category-Level MDS.



Εικόνα 5: Category-Level Dendrogram.

Για να συγκρίνουμε τον ταξινομητή που χρησιμοποιεί LDA, φτιάξαμε έναν αντίστοιχο ταξινομητή SVM, ο οποίος έτρεξε για έναν μόνο συμμετέχοντα. Η ακρίβεια που έδωσε ήταν 37.47%, που ήταν μικρότερη της αντίστοιχης ακρίβειας που έδωσε ο ταξινομητής LDA (39.45%). Επιπλέον, ο ταξινομητής με το SVM χρειάστηκε περίπου 34 ώρες για να ολοκληρώσει την εκπαίδευση και τις προβλέψεις, ενώ ο LDA χρειάστηκε 40-90 λεπτά, αναλόγως τις δυνατότητες του υπολογιστή. Οπότε επιλέγαμε να χρησιμοποιήσουμε LDA για όλες τις υπόλοιπες ταξινομήσεις που εκτελέσαμε.


Προκειμένου να ερευνήσουμε την τοπογραφία της διαχωρησιμότητας των κατηγοριών, εκτελέσαμε τοπική ταξινόμηση για τις 6 κατηγορικές κλάσεις, δηλαδή εξαγάγαμε ποσοστά επιτυχίας για κάθε ένα από τα 124 ηλεκτρόδια. Στο παρακάτω διάγραμμα, αποτυπώνουμε τη σχέση μεταξύ της ακρίβειας και των ηλεκτροδίων. Αυτό απεικονίζει τα αποτελέσματα ενός συμμετέχοντα, ωστόσο και των υπολοίπων 4 το προσομοιάζουν αρκετά στη μορφή, δηλαδή, οι κορυφές του διαγράμματος βρίσκονται σχεδόν στα ίδια ηλεκτρόδια. Οι ακρίβειες ανάμεσα στα ηλεκτρόδια κυμαίνονται περίπου από 20% έως 34%. Τα ελάχιστα και τα μέγιστα στους υπόλοιπους συμμετέχοντες που εξετάσαμε κυμάνθηκαν από 18%-20% και από 30%-35% αντίστοιχα. Συμπερασματικά, βλέπουμε ότι κάποια ηλεκτρόδια (τα ίδια πάντα) συνεισφέρουν περισσότερο στην ακρίβεια του μοντέλου.



Εικόνα 6: Η ακρίβεια για κάθε ηλεκτρόδιο ξεχωριστά.

Στη συνέχεια εξετάσαμε ταξινομήσεις σε χρονικά υποσύνολα. Δηλαδή για κάθε παράθυρο 80ms (5 χρονικά δείγματα) συνδυάσαμε τα δεδομένα από όλα τα ηλεκτρόδια και εξαγάγαμε τις αντίστοιχες ακρίβειες και confusion matrices. Συνολικά είχαμε 9 παράθυρα των 80ms, ενώ κάθε παράθυρο είχε επικάλυψη με το επόμενο κατά 2 χρονικά δείγματα. Αρχικά, υπολογίσαμε τον μέσο όρο των ποσοστών επιτυχίας από 5 συμμετέχοντες για κάθε χρονικό παράθυρο. Στα πρώτα δύο χρονικά παράθυρα (0-128ms) η συνολική ακρίβεια ήταν αντίστοιχα 16.41% και 18.54%. Στο τρίτο χρονικό παράθυρο (96-176ms) υπήρξε απότομη αύξηση της ακρίβειας σε 28.04%, και στα χρονικά παράθυρα 4 με 6 (144-320ms) περεταίρω αύξηση, συγκεκριμένα 34.77%, 34.08% και 32.34%. Στα επόμενα τρία χρονικά παράθυρα η ακρίβεια μειώθηκε στα ποσοστά 28.26%, 24.64% και 24.2%. Συμπεραίνουμε λοιπόν ότι τα παράθυρα 4 με 6 συμβάλλουν περισσότερο στην επιτυχημένη ταξινόμηση των κατηγοριών.

Συνδυάσαμε τα αποτελέσματα από 3 συμμετέχοντες και τυπώσαμε το παρακάτω διάγραμμα, το οποίο δείχνει την ακρίβεια του ταξινομητή σε κάθε χρονικό παράθυρο, ανά κατηγορία. Το διάγραμμα αυτό το φτιάξαμε κρατώντας τα στοιχεία της διαγωνίου από όλα τα confusion matrices, δηλαδή, για την κάθε κατηγορία συνδυάσαμε σε μία λίστα τις αντίστοιχες τιμές της διαγωνίου για κάθε χρονικό παράθυρο. Παρατηρούμε ότι η κλάση HF έχει πολύ μεγαλύτερη ακρίβεια από όλες τις υπόλοιπες, 40%-50%, ενώ οι υπόλοιπες είναι γύρω στο 20%-30%. Ειδικότερα, η κλάση FV έχει τα χαμηλότερα ποσοστά επιτυχίας σε όλα τα χρονικά παράθυρα. Τα αποτελέσματα αυτά συμβαδίζουν με το γεγονός ότι στην ταξινόμηση ολόκληρου του συνόλου δεδομένων η κλάση HF είχε το μεγαλύτερο ποσοστό επιτυχίας, ενώ η κλάση FV είχε το χαμηλότερο ποσοστό επιτυχίας. Επιπλέον, παρατηρούμε ότι στα δύο πρώτα χρονικά παράθυρα (0-128ms) έχουμε πολύ χαμηλή ακρίβεια σε όλες τις κλάσεις. Τα αποτελέσματα βελτιώνονται στο επόμενο χρονικό παράθυρο (96-176ms) και στα χρονικά παράθυρα 4 με 6 (144-320ms), ενώ στα επόμενα έχουμε πάλι μία πτώση. Αυτά συμβαδίζουν και με τα αποτελέσματα της έρευνας, στα οποία ωστόσο η πτώση της ακρίβειας αρχίζει να παρατηρείται από το χρονικό παράθυρο 6 (240-320ms).




Εικόνα 7: Διάγραμμα ακρίβειας-χρόνου.

Εν συνεχεία εφαρμόσαμε τη μέθοδο RSA και εξαγάγαμε τα αντίστοιχα διαγράμματα MDS και δένδροδιαγράμματα για κάθε χρονικό παράθυρο χρησιμοποιώντας τα confusion matrices. Οι αντίστοιχες εικόνες βρίσκονται στο Appendix στο τέλος της εργασίας. Όπως παρατηρούμε από τα διαγράμματα MDS, στο πρώτο χρονικό παράθυρο κάποιες κατηγορίες δεν είναι καθόλου διαχωρισμένες μεταξύ τους (AF, HF, HB). Ωστόσο, στα επόμενα χρονικά παράθυρα οι κατηγορίες αρχίζουν να διαχωρίζονται περισσότερο μεταξύ τους. Συγκεκριμένα, στα χρονικά παράθυρα 4 και 5 οι κατηγορίες παρουσιάζουν τη μέγιστη διαχωρισσιμότητα. Στα υπόλοιπα παρατηρούμε ομοίως μικρότερη διαχωρισσιμότητα κάποιων κλάσεων. Μάλιστα, παρατηρούμε ότι κάθε φορά έχουμε διαφορετικές κατηγορίες που δεν διαχωρίζονται μεταξύ τους. Τα αποτελέσματα αυτά, φαίνεται να συμβαδίζουν με τα αποτελέσματα από το παραπάνω διάγραμμα. Η ιεραρχική δομή των κατηγοριών φαίνεται με τα αντίστοιχα δένδροδιαγράμματα. Παρατηρούμε ότι υπάρχουν αρκετές διαφοροποιήσεις ανάμεσα στα διάφορα χρονικά παράθυρα. Παρόλα αυτά, στα χρονικά παράθυρα 3-7, όπου οι κατηγορίες είναι καλύτερα διαχωρισμένες με βάση τα διαγράμματα MDS, ο διαχωρισμός των κατηγοριών είναι παρόμοιος. Σε όλα ο διαχωρισμός γίνεται πρώτα με τις κατηγορίες FV και IO, ενώ σε κάποια φαίνεται να γίνεται και νωρίτερα ο διαχωρισμός των κατηγοριών από εικόνες ζώων (AB, AF) από τις εικόνες ανθρώπων (HB, HF). Στα χρονικά παράθυρα 8 και 9 τα δένδροδιαγράμματα είναι ακριβώς τα ίδια.

Πραγματοποιήσαμε, επιπλέον, ταξινομήσεις για κάθε ηλεκτρόδιο σε κάθε χρονικό παράθυρο. Τα ποσοστά


επιτυχίας στα μεσσαία χρονικά παράθυρα είναι συνολικά μεγαλύτερα για όλα τα ηλεκτρόδια. Δηλαδή, στα δύο πρώτα χρονικά παράθυρα έχουμε ακρίβειες περίπου 15%-18%, ενώ στα μεσσαία χρονικά παράθυρα έχουμε μέγιστη ακρίβεια κοντά στο 30%. Επίσης, όπως αναμέναμε με βάση τα προηγούμενα αποτελέσματα, στα τελευταία χρονικά παράθυρα τα ποσοστά επιτυχίας μειώνονται περίπου στο 18%-20%. Τέλος, έχουμε αντίστοιχες κορυφές στα ποσοστά επιτυχίας που δίνουν τα ηλεκτρόδια με αυτές που παρατηρήσαμε στην χωρική ταξινόμηση.

Σε επόμενο στάδιο δοκιμάσαμε να ταξινομήσουμε σε κατηγορικό επίπεδο για όλες τις κλάσεις χρησιμοποιώντας νευρωνικά δίκτυα. Αρχικά, τρέξαμε ένα απλό CNN για όλες τις 6 κλάσεις, και για τους 10 συμμετέχοντες. Έπειτα, λαμβάνουμε τα τελικά αποτελέσματα, υπολογίζοντας τη μέση τιμή της ακρίβειας για κάθε συμμετέχοντα, ενώ αθροίσαμε όλα τα CMs, και ύστερα τα κανονικοποιήσαμε. Η διαδικασία αυτή εφαρμόστηκε σε όλα τα μοντέλα νευρωνικών δικτύων που δοκιμάσαμε. Εδώ μπορούμε να παρατηρήσουμε πως το CNN παρουσιάζει σταθερά καλύτερη απόδοση από την μέθοδο LDA, εκτός της κατηγορίας HF, την οποία το LDA το βρίσκει με μεγάλη επιτυχία 61%, ενώ το CNN με 55%. Ωστόσο το νευρωνικό μας δίκτυο στις άλλες κατηγορίες είναι πιο επιτυχημένο.




Εικόνα 8: CM of simple CNN.

Χρησιμοποιήσαμε το ίδιο CNN με πριν για τις 6 κλάσεις, εφόσον όμως προηγήθηκε της εκπαίδευσης PCA με SVD στα δεδομένα. Ορίσαμε  $k = 180$ , καθώς από τη συνάρτηση LDA που έχουμε φτιάξει, η τιμή του βέλτιστου  $k$  υπολογιζόταν αρκετές φορές κοντά στο 180. Παρατηρήσαμε πως να μην είχαμε πολύ πιο γρήγορη εκπαίδευση του μοντέλου μας λόγω της μείωσης των διαστάσεων, ωστόσο υπήρξε εμφανής μείωση απόδοσης, γεγονός που δείχνει ότι χάθηκε σημαντική πληροφορία. Αυτό είναι μια ένδειξη πως η οπτικοποίηση των δεδομένων σαν εικόνες όπως περιγράψαμε στην παράγραφο 4.6, συμβάλλει στην απόδοση του νευρωνικού δικτύου με συνέλιξη (CNNs).




Εικόνα 9: CM of simple CNN after PCA.

Επιπρόσθετα, δημιουργήσαμε ένα Deep CNN για τον ίδιο σκοπό, έχοντας εφαρμόσει PCA με SVD στα δεδομένα μας με  $k = 180$ . Εδώ παρατηρούμε πως, ενώ θεωρητικά το μοντέλο θα μπορούσε να δώσει καλύτερα αποτελέσματα, η απόδοση δεν αυξάνεται. Επομένως, πλέον μπορούμε να αποφανθούμε πως η μείωση των διαστάσεων δε συνέβαλε στη βελτίωση της απόδοσης.



Εικόνα 10: CM of deep CNN after PCA.


Τέλος, δοκιμάσαμε την τεχνική Transfer Learning με τη χρήση του VGG16 NET, το οποίο είναι μια ειδική κατηγορία συνελκτικού δικτύου. Αλλάζοντας λίγο την αρχιτεκτονική, για να προσαρμοστεί στις δικές μας ανάγκες, το εκπαιδεύσαμε με fine tuning και πήραμε το παρακάτω αποτέλεσμα. Παρατηρούμε, πως δεν λαμβάνουμε καλύτερη απόδοση από τα άλλα δίκτυα, ωστόσο αυτό είναι λογικό, γιατί το μοντέλο αυτό απαιτεί μεγάλο όγκο δεδομένων και αρκετές εποχές για να εκπαιδευτεί, λόγω της πολυπλοκότητας στην αρχιτεκτονική του. Είναι εμφανές πως δε μπορεί να διακρίνει τις κατηγορίες μεταξύ τους και δίνει περισσότερη έμφαση στις 3 από τις 6, Animal Face, Fruit Vegetable και Inanimate Object.



Εικόνα 11: CM of Transfer Learning using VGG16.

## 5.2 Exemplar-Level Ταξινόμησης

Αρχικά εκτελέσαμε ταξινόμηση με χρήση του ταξινομητή με το LDA για την exemplar-level κατηγορία, δηλαδή για 72 κλάσεις συνολικά. Το συνολικό ποσοστό επιτυχίας από τους 5 συμμετέχοντες είναι 8.54%. Παρακάτω παραθέτουμε τον confusion matrix ενός συμμετέχοντα για τη συγκεκριμένη ταξινόμηση. Η εκτέλεση του διήρκεσε 1 ώρα περίπου, ενώ το ποσοστό επιτυχίας ήταν 6.85%. Παρατηρούμε ότι η διαγώνιος έχει πιο έντονο χρώμα, ενώ οι 12 κατηγορίες της HF φαίνονται περισσότερο από τις υπόλοιπες κατηγορίες. Δηλαδή, ο ταξινομητής συγχέει τα ανθρώπινα πρόσωπα μεταξύ τους, ωστόσο δεν τα συγχέει πολύ με τις υπόλοιπες κατηγορίες. Δε φαίνεται να υπάρχει εμφανής διαχωρισμός μεταξύ μιας κατηγορίας από τις υπόλοιπες.

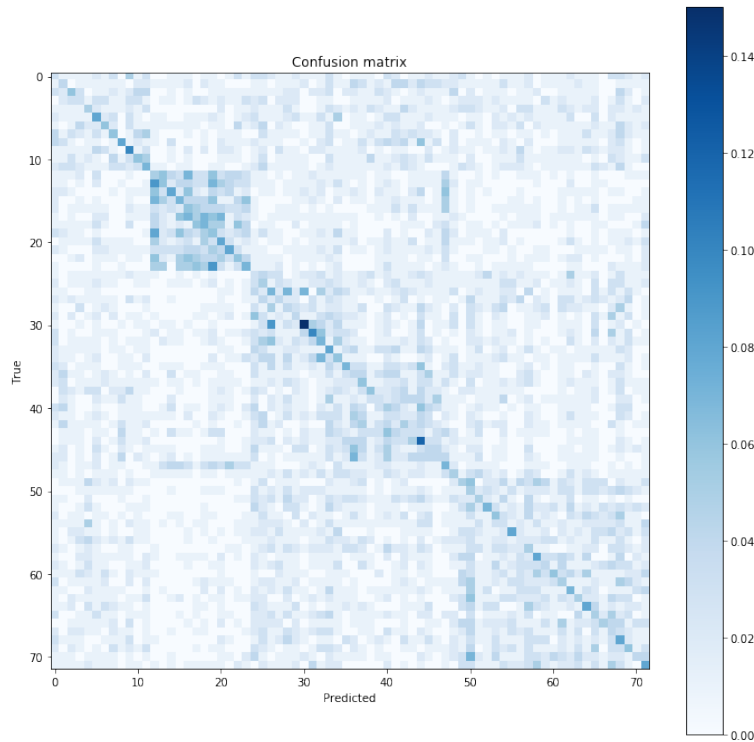


Εικόνα 12: Exemplar-Level CM of LDA.



Εφαρμόσαμε ταξινόμηση με LDA για τους 5 συμμετέχοντες για κάθε χρονικό παράθυρο. Οι μέσες τιμές των αποτελεσμάτων από τους 5 συμμετέχοντες είναι αρκετά χαμηλά, όπως ήταν αναμενόμενο από την ακρίβεια σε όλα τα χρονικά παράθυρα μαζί. Συγκεκριμένα στα πρώτα δύο χρονικά παράθυρα η ακρίβεια είναι μόλις γύρω στο 1.5%. Στα επόμενα αυξάνεται λίγο και φτάνει τη μέγιστη τιμή στο τέταρτο χρονικό παράθυρο με ακρίβεια 6.97%. Στη συνέχεια, μειώνεται σταδιακά και τελικά πέφτει στο 3% στο τελευταίο χρονικό παράθυρο. Τα αποτελέσματα αυτά σε μορφή συμβαδίζουν με τα αντίστοιχα αποτελέσματα από τα προηγούμενα χρονικά υποσύνολα. Πιο αναλυτικά, τα αντίστοιχα ποσοστά που αναφέραμε φαίνονται πιο αναλυτικά στον πίνακα στην ενότητα 5.5.

Ως επόμενο βήμα εφαρμόσαμε το απλό CNN στα δεδομένα μας για 72 κλάσεις. Η ακρίβεια που λάβαμε ήταν στο 6%, δηλαδή χαμηλότερη από τον ταξινομητή με το LDA. Παρατηρούμε κάποια μοτίβα στο confusion matrix, συγκεκριμένα, η κύρια διαγώνιος που συμβολίζει τις πραγματικές προβλέψεις έχει πιο υψηλό ποσοστό επιτυχίας από τις άλλες, όπως επίσης διακρίνονται κάποια μικρά τετραγωνάκια γύρω από την κύρια διαγώνιο με μεγαλύτερο ποσοστό επιτυχίας από τα άλλα. Εκεί φαίνεται πως όταν το μοντέλο μας κάνει λάθος πρόβλεψη τότε προβλέπει μια διπλανή κατηγορία που έχει σχέση με αυτήν και όχι κάτι πολύ διαφορετικό. Συγκεκριμένα, αυτό είναι πιο έντονο για την κατηγορία HF, ενώ οι κατηγορίες FV και IO φαίνεται να έχουν ενωθεί σε μία μεγαλύτερη κατηγορία και δεν διαχωρίζονται.




Εικόνα 13: Exemplar-Level CM of simple CNN.

### 5.3 Ενδο-κατηγοριακές Ταξινομήσεις


Οι εικόνες της κατηγορίας HF παρήγαγαν υψηλή ακρίβεια στην ταξινόμηση σε κατηγορικό επίπεδο για τις έξι κλάσεις, καθώς και υψηλή ενδο-κατηγοριακή σύγχυση στην περίπτωση ταξινόμησης 72 κλάσεων. Η κατηγορία IO παρουσίασε τη μικρότερη συνοχή ως κατηγορία. Δεδομένων των αντίθετων αποτελεσμάτων από αυτές τις δύο κατηγορίες, πραγματοποιήσαμε exemplar-level ταξινομήσεις για κάθε κατηγορία ξεχωριστά. Επιπλέον, εκτελέσαμε μία ταξινόμηση ανάμεσα σε αυτές τις δύο κλάσεις. Σε όλες αυτές τις ταξινομήσεις χρησιμοποιήθηκε αρχικά ο ταξινομητής LDA.

Το αποτέλεσμα της ταξινόμησης σε exemplar-level της κατηγορίας HF από τους 5 συμμετέχοντες ήταν 14.79%, που είναι αρκετά χαμηλό. Αυτό είναι μάλλον αναμενόμενο καθώς όπως είδαμε και στην ταξινόμηση 72 κλάσεων, ο ταξινομητής συγχέει έντονα τις κλάσεις της κατηγορίας HF. Το αντίστοιχο αποτέλεσμα της κατηγορίας IO από όλους τους συμμετέχοντες είναι 27.21%. Συνεπώς, ο ταξινομητής σφάλει λιγότερο σε αυτήν

την περίπτωση. Παρακάτω παρουσιάζουμε τους confusion matrices από έναν συμμετέχοντα από τις ταξινομήσεις σε exemplar-level της κατηγορίας HF και της κατηγορίας IO. Οι αντίστοιχες ακρίβειες ήταν 16.42% και 29.05%. Όπως περιμέναμε, στη δεύτερη περίπτωση είναι πιο ξεκάθαρη η διαγώνιος του confusion matrix, ενώ στην κατηγορία HF έχουμε μεγαλύτερα ποσοστά λάθους.



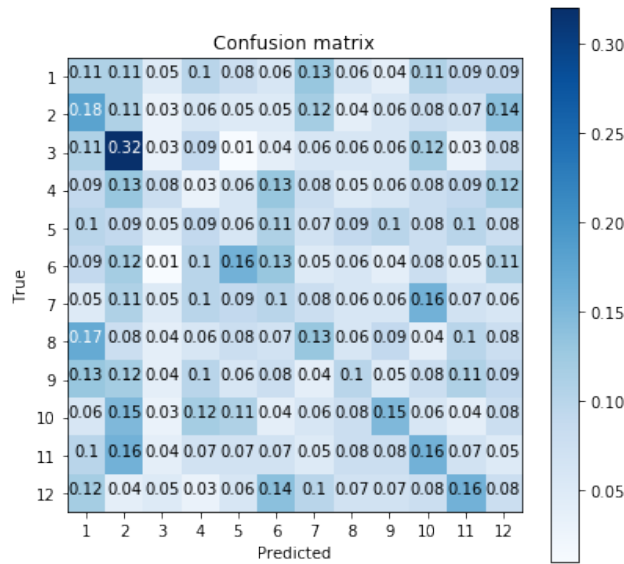
Εικόνα 14: Within-category HF.



Εικόνα 15: Within-category IO.

Εκτελέσαμε ταξινομήσεις σε exemplar-level για κάθε μία από αυτές τις κατηγορίες για κάθε χρονικό παράθυρο. Με βάση τα αποτελέσματα από τους 5 συμμετέχοντες για την κατηγορία HF, η ακρίβεια στα δύο πρώτα χρονικά παράθυρα είναι αρκετά χαμηλή, γύρω στο 8.5%, ενώ η μέγιστη τιμή της είναι στο τέταρτο χρονικό παράθυρο, όπου είναι 15.74%. Στα επόμενα χρονικά παράθυρα η ακρίβεια πέφτει λίγο και στα δύο τελευταία πέφτει γύρω στο 11%. Αντίθετα, για τα αντίστοιχα αποτελέσματα για την κατηγορία IO έχουμε πάλι ακρίβεια γύρω στο 8%-9% στα πρώτα δύο χρονικά παράθυρα. Στη συνέχεια, η ακρίβεια αυξάνεται απότομα και φτάνει τη μέγιστη τιμή της στο έκτο χρονικό παράθυρο, 22.17%. Ύστερα πάλι μειώνεται και πέφτει στο τελευταίο χρονικό παράθυρο κοντά στο 12.5%. Τα αποτελέσματα αυτά συμβαδίζουν ως προς την ακρίβεια με τα αντίστοιχα ποσοστά επιτυχίας για όλα τα χρονικά παράθυρα μαζί, ενώ συμβαδίζουν επίσης στη μορφή και με τα αποτελέσματα από τα προηγούμενα χρονικά υποσύνολα. Τα αποτελέσματα αυτά φαίνονται και στον πίνακα στην ενότητα 5.5 πιο αναλυτικά.


Στην κατηγορία HF δοκιμάσαμε να χρησιμοποιήσουμε ένα πιο βαθύ Συνελκτικό Δίκτυο, συγκεκριμένα με 5 συνελκτικά επίπεδα για όλους τους συμμετέχοντες. Παρατηρούμε, πως η απόδοση στο συγκεκριμένο νευρωνικό είναι αρκετά χαμηλή, της τάξης του 14%. Ωστόσο αυτό μπορεί να οφείλεται στην έλλειψη αρκετών δεδομένων για να έχουμε καλύτερη γενίκευση και στην έλλειψη πόρων ώστε να γίνει η εκπαίδευση σε περισσότερες εποχές. Ωστόσο, τα αποτελέσματα είναι αρκετά κοντά με αυτά που έδωσε ο ταξινομητής με το LDA.



Εικόνα 16: Within-Category CM of deep CNN.

#### 5.4 Δυαδική ταξινόμηση ανάμεσα στις κλάσεις HF και IO

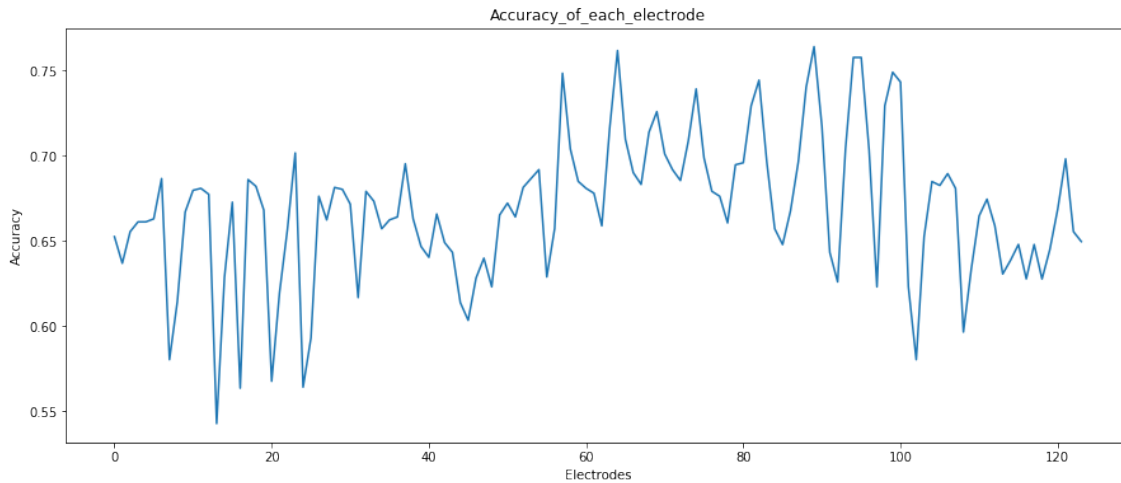
Ακολουθώντας εφαρμόζουμε δυαδική ταξινόμηση ανάμεσα στις κλάσεις HF και IO. Παρατηρήσαμε πως τα μοντέλα μας προβλέπουν με υψηλά ποσοστά την HF κατηγορία επομένως και εδώ αναμένουμε ακόμα υψηλότερα ποσοστά λόγω του ότι έχουμε μόνο 2 κατηγορίες. Η μέση ακρίβεια από όλους τους συμμετέχοντες είναι 80.51%. Το αποτέλεσμα αυτό είναι πράγματι πολύ μεγάλο και συμπεραίνουμε ότι ο ταξινομητής με LDA μπορεί να διαχωρίσει αρκετά ικανοποιητικά αυτές τις δύο κλάσεις. Ακολουθεί ο confusion matrix ενός από τους συμμετέχοντες, του οποίου η ακρίβεια είναι 78.53%. Είναι φανερό ότι ο ταξινομητής δε συγχέει τις δύο αυτές κλάσεις όσο άλλες μεταξύ τους.



Εικόνα 17: 2-Category-Level CM of LDA.

Εφαρμόσαμε δυαδική ταξινόμηση ανάμεσα στις δύο κλάσεις για κάθε ηλεκτρόδιο ξεχωριστά. Όλα τα ηλεκτρόδια έδωσαν σχετικά καλές ακρίβειες. Συγκεκριμένα, τα ποσοστά επιτυχίας ενός συμμετέχοντα κυμαίνονταν από 55% έως 75%, ανάλογα το ηλεκτρόδιο. Παρατηρήσαμε πάλι ότι υπάρχουν έντονες κορυφές μεγίστου και ελαχίστου ανάμεσα στα διάφορα ηλεκτρόδια, ενώ φαίνεται να είναι πάντα τα ίδια ηλεκτρόδια που δίνουν το


μεγαλύτερο ποσοστό επιτυχίας. Στο παρακάτω διάγραμμα φαίνεται η σχέση μεταξύ της ακρίβειας και των ηλεκτροδίων. Τα αποτελέσματα για τους υπόλοιπους συμμετέχοντες είναι παρόμοια.



Εικόνα 18: Η ακρίβεια για κάθε ηλεκτρόδιο ξεχωριστά.

Εφαρμόσαμε, επίσης, δυαδική ταξινόμηση ανάμεσα στις δύο κλάσεις για κάθε χρονικό παράθυρο ξεχωριστά. Τα συνολικά αποτελέσματα από τους 5 συμμετέχοντες δείχνουν ότι στα πρώτα δύο χρονικά παράθυρα έχουμε ακρίβεια λίγο μεγαλύτερη από 50%. Στο τρίτο χρονικό παράθυρο έχουμε μία απότομη αύξηση της ακρίβειας σε 70.85%, ενώ η μέγιστη τιμή της ακρίβειας είναι στο τέταρτο χρονικό παράθυρο, 77.14%. Στη συνέχεια, η ακρίβεια μειώνεται ώπου πέφτει γύρω στο 64% στα τελευταία χρονικά παράθυρα. Τα αποτελέσματα αυτά συμβαδίζουν και ως προς τη μορφή και ως προς την ακρίβεια με προηγούμενα αποτελέσματα. Πιο αναλυτικά, τα αντίστοιχα ποσοστά φαίνονται στον πίνακα στην ενότητα 5.5.

Ύστερα, κάνουμε τη σύγκριση με δύο νευρωνικά δίκτυα για όλους τους συμμετέχοντες. Διαπιστώνουμε πως το νευρωνικό DFNN με PCA έβγαλε ένα ποσοστό επιτυχίας της τάξεως του 75% ενώ το CNN 81.45%. Οπότε, παρατηρούμε πάλι πως το CNN ξεπέρασε το απλό νευρωνικό, χρησιμοποιώντας το σύνολο δεδομένων σαν εικόνες με ηλεκτρόδια. Συμπερασματικά, το CNN για τη δυαδική ταξινόμηση ανάμεσα στις κλάσεις HF και IO μας έδωσε το καλύτερο αποτέλεσμα.



Εικόνα 19: 2-Category-Level CM of (a) DFNN and (b) CNN.

## 5.5 Στατιστική Ανάλυση

Ο παρακάτω πίνακας περιέχει τις ακρίβειες (accuracies), τις τυπικές αποκλίσεις (standard deviations) και τις  $p$ -τιμές σημαντικότητας για όλες τις ταξινομήσεις με τον αλγόριθμο LDA, για ολόκληρο το χρονικό παράθυρο 0-496 ms αλλά και για κάθε χρονικό παράθυρο του temporal classification. Η σημαντικότητα ελέγχθηκε με τον υπολογισμό της  $p$ -τιμής υπό τη μηδενική υπόθεση  $H_0$  Διωνυμικής κατανομής  $B(X, N, p)$ , όπου  $Q$  το πλήθος των σωστών ταξινομήσεων σε ένα test fold,  $N$  το συνολικό πλήθος ταξινομήσεων που έγιναν σε ένα test fold, και  $p$  η prior πιθανότητα, ή αλλιώς το prior ποσοστό σωστής ταξινόμησης, που αντιστοιχεί σε  $1/n$  όταν έχουμε  $n$  κατηγορίες. Η  $H_0$  εκφράζει το γεγονός "οι ακρίβειες του δείγματος να είναι τυχαία και να μην υπάρχει σχέση με την κατανομή στον πληθυσμό". Αν η  $p$ -τιμή είναι μικρή τότε απορρίπτουμε την  $H_0$  και τα αποτελέσματά μας είναι στατιστικά σημαντικά. Αυτό που παρατηρούμε είναι ότι σε ολόκληρο το χρονικό παράθυρο 0-496 ms όλες οι  $p$ -τιμές είναι μικρές, και άρα τα αποτελέσματά μας στατιστικά σημαντικά. Όσον αφορά τα χρονικά παράθυρα, οι  $p$ -τιμές στο πρώτο και το δεύτερο είναι αρκετά υψηλές κι έτσι δεν μπορούμε να μιλήσουμε για στατιστική σημαντικότητα των αποτελεσμάτων. Στα επόμενα χρονικά παράθυρα ωστόσο οι  $p$ -τιμές είναι πολύ μικρές και δεχόμαστε τη σημαντικότητα των αποτελεσμάτων. Σε σχέση με το αντίστοιχο στατιστικό summary της έρευνας, έχουμε επιτύχει ίδια αποτελέσματα όσον αφορά τη σημαντικότητα και τις ακρίβειες, καθώς κυμαίνονται στο ίδιο επίπεδο με κάποιες μικρές διαφορές. Οι τυπικές αποκλίσεις που έχουμε επιτύχει είναι μικρότερες. Οι διαφορές αυτές πολύ πιθανό να εξηγούνται κατά μεγάλο μέρος από το γεγονός ότι χρησιμοποιήσαμε τα μισά δεδομένα (5 συμμετέχοντες) από την έρευνα (10 συμμετέχοντες).

		0-496ms	tw 0-4	tw 3-7	tw 6-10	tw 9-13	tw 12-16	tw 15-19	tw 18-22	tw 21-25	tw 24-28
6 classes	accuracy %	37.463	16.41	18.54	28.04	34.77	34.08	32.34	28.26	24.64	24.2
	sample std	1.661	0.6504	0.4029	0.9542	1.713	2.3572	1.4505	2.0719	2.3494	3.7905
	p-value	1.102e-29	5.807e-01	1.403e-01	8.095e-11	1.726e-23	8.314e-22	3.086e-18	4.097e-11	3.337e-06	8.939e-06
12 classes - HF	accuracy %	14.791	8.58	8.72	11.69	15.74	14.75	12.75	12.2	11.34	10.92
	sample std	1.936	1.6389	1.0324	1.7731	1.8993	1.9021	1.9262	1.8309	1.95	0.974
	p-value	2.127e-06	4.701e-01	4.079e-01	6.416e-03	3.834e-08	1.235e-06	4.179e-04	1.764e-03	1.395e-02	2.834e-02
12 classes - IO	accuracy %	27.211	8.34	9.72	16.67	19.95	21.57	22.17	16.67	14.1	12.59
	sample std	5.723	0.4869	0.8308	2.6852	5.3198	6.0019	6.37	3.3409	3.5925	1.4584
	p-value	1.014e-36	5.335e-01	1.569e-01	8.363e-10	1.618e-16	3.321e-20	1.139e-21	8.363e-10	8.326e-06	6.865e-04
2 classes - HF vs IO	accuracy %	80.509	50.78	54.47	70.85	77.14	74.9	71.98	67.36	63.66	64.46
	sample std	1.523	1.557	2.0009	1.6855	0.9515	3.164	2.4646	3.5935	5.2983	4.9621
	p-value	1.325e-46	3.792e-01	2.396e-02	4.413e-22	1.211e-36	3.907e-31	1.763e-24	9.683e-16	2.281e-10	2.168e-11
72 classes - Exemplars	accuracy %	8.542	1.36	1.75	4.02	6.97	6.63	6.05	4.54	3.43	3
	sample std	3.314	0.1116	0.1961	0.6209	1.9255	2.5032	2.2325	1.7331	1.214	0.7073
	p-value	4.542e-21	5.801e-01	2.958e-01	5.488e-05	7.95e-15	2.19e-13	2.511e-11	1.67e-06	1.167e-03	6.836e-03

Εικόνα 20: Πίνακας αποτελεσμάτων ταξινόμησης.

## 6 Συμπεράσματα/Μελλοντική Έρευνα

Ένα τρέχον ερευνητικό θέμα είναι η κατανόηση του σήματος EEG και η σύνδεσή του με διάφορους παράγοντες (κούραση, επίπεδο προσοχής, θόρυβος κλπ) [8]. Οι νευρικές δραστηριότητες του ανθρώπινου εγκεφάλου δημιουργούν ένα από τα πιο σημαντικά βιοϊατρικά σήματα τα οποία αποτελούν την πηγή κωδικοποιημένων πληροφοριών σχετικά με το περιβάλλον του ανθρώπου και τις εσωτερικές καταστάσεις (internal states) του. Η κατανόηση των χαρακτηριστικών των νευρικών δεδομένων μπορεί να χρησιμοποιηθεί για την αποκωδικοποίηση των ανθρώπινων σκέψεων και ενεργειών η οποία και θα βοηθούσε στη διάγνωση νευροψυχολογικών παθήσεων του εγκεφάλου. Δηλαδή, το κλινικό αντίκτυπο στο οποίο θα μπορούσε να καταλήξει μία τέτοια έρευνα είναι μέσω των σημάτων που θα λαμβάνουμε από τον εγκέφαλο, να ελέγχουμε άμα είναι φυσιολογικά τα σήματα αυτά, όταν ο αντίστοιχος ασθενής εκτεθεί σε κάποιες εικόνες, ώστε να βρούμε κάποια πιθανή βλάβη του εγκεφάλου του νωρίτερα. Ακολουθώντας, πιθανές εφαρμογές στην κλινική ιατρική είναι, για παράδειγμα, η δημιουργία συστημάτων τα οποία επιτρέπουν σε ανθρώπους με αναπηρία να επικοινωνούν με άλλους ανθρώπους και να ελέγχουν το περιβάλλον τους. Για αυτές τις εφαρμογές, οι μέθοδοι

συλλογής δεδομένων εγκεφάλου, προεπεξεργασίας και ανάλυσής τους έχουν γίνει μία από τις πιο απαιτητικές προκλήσεις σε αυτόν τον τομέα τις τελευταίες δεκαετίες. Επομένως καθίσταται ιδιαίτερα σημαντική η ανάπτυξη τεχνικών μηχανικής και βαθιάς μάθησης που θα συνεισφέρουν στην ακριβέστερη κατανόηση των εγκεφαλικών διεργασιών και αναπαράστασεων, κάτι με το οποίο η παρούσα εργασία καταπιάνεται.

Η εργασία αυτή ανήκει λοιπόν στα πλαίσια των ερευνών αυτών σχετικά με την επεξεργασία και την αναπαράσταση οπτικών αντικειμένων στον εγκέφαλο, με την αξιοποίηση εν προκειμένω των σημάτων EEG. Μπορούμε αρχικά να πούμε ότι τα 500 πρώτα milliseconds από αποκρίσεις σε ερεθίσματα 72 εικόνων περιέχουν πληροφορία για την αποκωδικοποίηση κατηγοριών και exemplars. Οι confusion matrices που προέκυψαν από την ταξινόμηση 72 έμψυχων και άψυχων αντικειμένων χρησίμευσαν στο να δημιουργηθεί ένας χώρος ομοιότητας για τις category-exemplar ταξινομήσεις. Μπορούμε, συνοψίζοντας, να δηλώσουμε ότι η κατηγορία HF είχε τη μεγαλύτερη συνοχή και διαχωρισιμότητα από τις υπόλοιπες κατηγορίες, ενώ στις δύο κατηγορίες άψυχων αντικειμένων, IO και FV, υπήρξε σύγχυση στο διαχωρισμό.

Στη διεξαγωγή ταξινομήσεων σε χρονικά παράθυρα παρατηρούμε χαμηλά ποσοστά στα δύο πρώτα παράθυρα και ταυτόχρονα υψηλές  $p$ -τιμές, που σημαίνει ότι τα αποτελέσματα δεν έχουν στατιστική σημαντικότητα. Τα ενδιάμεσα χρονικά παράθυρα εμφανίζουν μεγαλύτερο ποσοστό ακρίβειας ενώ στα τελευταία η ακρίβεια πέφτει και πάλι (οι  $p$ -τιμές του ελέγχου εδώ δείχνουν στατιστική σημαντικότητα). Αυτό έρχεται σε συμφωνία με την έρευνα που μελετάμε και υποστηρίζει περαιτέρω αντίστοιχα ευρήματα άλλων ερευνών [6], ότι δηλαδή και πιο μικρά χρονικά δείγματα μπορούν να παρέχουν πληροφορία για την αναπαράσταση. Οι τυπικές αποκλίσεις ωστόσο εμφανίζουν αξιοσημείωτη διακύμανση και δεν είναι σταθερές στην εξέλιξη του χρόνου.

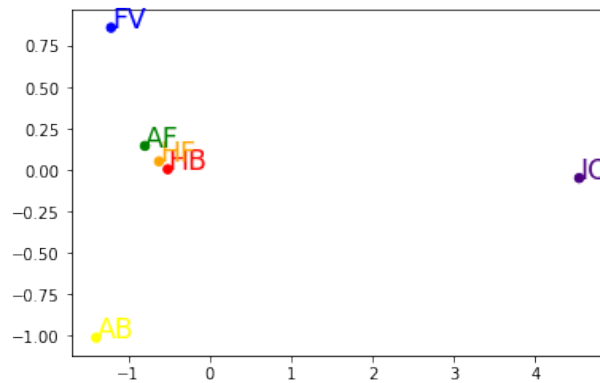
Η ταξινόμηση με χρήση δεδομένων από απομονωμένα ηλεκτρόδια έδωσε επίσης πληροφορία για την τοπογραφία της αναπαράστασης της κατηγορίας αντικειμένων, καθώς κάποια ηλεκτρόδια φάνηκε να συμβάλλουν περισσότερο στην ταξινόμηση σε σχέση με τα υπόλοιπα. Συγκεκριμένα, έγινε ταξινόμηση για τις 2 και για τις 6 κλάσεις για κάθε ηλεκτρόδιο ξεχωριστά, στο πλήρες χρονικό παράθυρο 0-496ms. Σε αμφότερες τις περιπτώσεις τα ηλεκτρόδια στο εύρος 58-98 πέτυχαν μεγαλύτερες ακρίβειες. Στα ηλεκτρόδια 0-58 παρατηρείται έντονη διακύμανση με κάποια ηλεκτρόδια να πετυχαίνουν υψηλή ακρίβεια και κάποια χαμηλή. Η ένδειξη για μεγαλύτερη συμβολή αυτών των ηλεκτροδίων θα μπορούσε να μελετηθεί περισσότερο σε επόμενες έρευνες.

Στη συγκεκριμένη έρευνα που πραγματοποιήσαμε, είδαμε πως τα νευρωνικά δίκτυα μπορούν να ξεπεράσουν σε ορισμένες περιπτώσεις τους κλασικούς αλγορίθμους μηχανικής μάθησης. Θα μπορούσε να ανοίξει ένα νέο κεφάλαιο της χρήσης νευρωνικών δικτύων σε EEG δεδομένα χρησιμοποιώντας αυτές τις πληροφορίες για καλύτερη εκπαίδευση. Ένα επόμενο βήμα θα ήταν η σχεδίαση πιο περίπλοκων αρχιτεκτονικών κατάλληλα σχεδιασμένων για το πρόβλημα των EEG δεδομένων, όπως ένας συνδυασμός LSTM-CNN[7] για να χρησιμοποιήσουμε και την έννοια του χρόνου.


Τέλος, είναι σημαντικό να τονίσουμε στοιχεία που θα μπορούσαμε να βελτιώσουμε στην εργασία μας. Κατ'αρχάς, η αξιοποίηση όλων των δεδομένων και η χρήση υπολογιστών με περισσότερες δυνατότητες αδιαμφισβήτητα θα βοηθούσε στη διαδικασία εκπαίδευσης/ταξινόμησης. Θα μπορούσε επίσης να έχει προηγηθεί μια στατιστική ανάλυση του σήματος με στατιστικές μεθόδους και οπτικοποιήσεις, σε ότι αυτό είναι εφικτό, έτσι ώστε να αναδειχτούν χαρακτηριστικά των δεδομένων, όπως η κατανομή τους, η ενδεχόμενη γραμμικότητα ή γραμμικές εξαρτήσεις, έκτοπα σημεία και άλλα. Αυτό ενδεχομένως να υποδείκνυε ποια μοντέλα είναι πιο κατάλληλα να επιλέξουμε. Τέλος θα μπορούσαμε να εξετάσουμε πιο ενδελεχώς την επιλογή υπερπαραμέτρων των μοντέλων μας με τη χρήση grid search ή άλλων αντίστοιχων τεχνικών.

## Παράρτημα

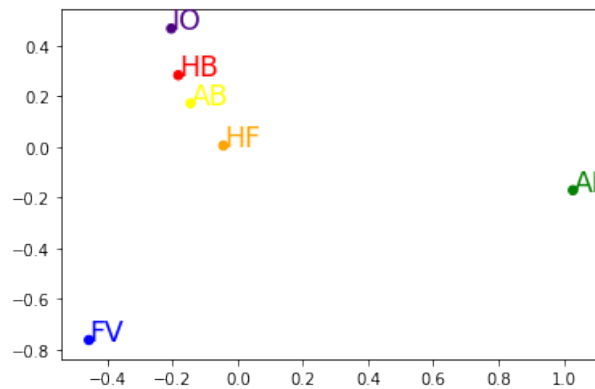
### Α. MDS και Δενδρογράμματα της Χρονικής Ταξινόμησης για τις κατηγορικές κλάσεις




Εικόνα 21: MDS (0-80ms).



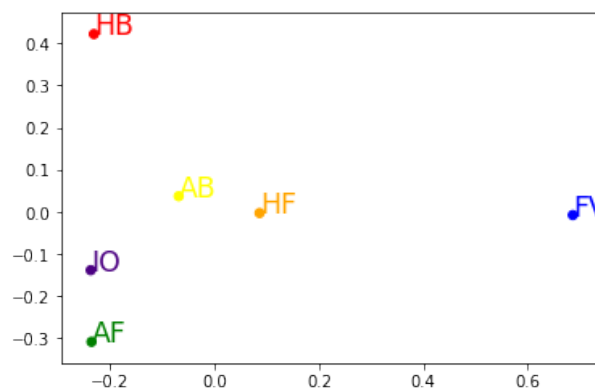
Εικόνα 22: Dendrogram (0-80ms).




Εικόνα 23: MDS (48-128ms).



Εικόνα 24: Dendrogram (48-128ms).




Εικόνα 25: MDS (96-176ms).




Εικόνα 26: Dendrogram (96-176ms).







Εικόνα 27: MDS (144-224ms).



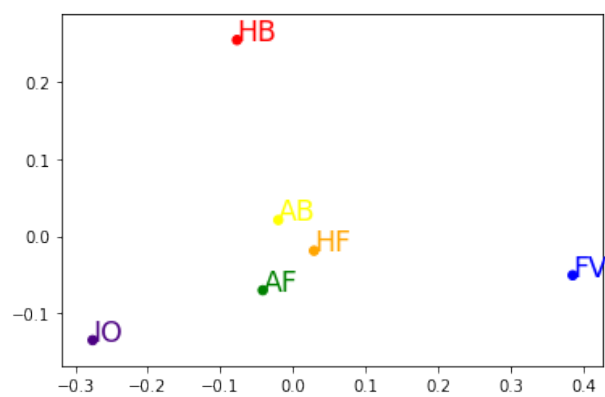
Εικόνα 28: Dendrogram (144-224ms).




Εικόνα 29: MDS (192-272ms).




Εικόνα 30: Dendrogram (192-272ms).




Εικόνα 31: MDS (240-320ms).




Εικόνα 32: Dendrogram (240-320ms).




Εικόνα 33: MDS (288-368ms).




Εικόνα 34: Dendrogram (288-368ms).




Εικόνα 35: MDS (336-416ms).



Εικόνα 36: Dendrogram (336-416ms).



Εικόνα 37: MDS (384-464ms).



Εικόνα 38: Dendrogram (384-464ms).

## Αναφορές

- [1] Haynes JD, Rees G Decoding mental states from brain activity in humans. *Nat Rev Neurosci* 7: 523–534. *Decoding mental states from brain activity in humans. Nat Rev Neurosci* 7: 523–534.
- [2] Warrington EK, Shallice T. Category specific semantic impairments. *Brain* 107(Pt 3): 829–854.
- [3] Kriegeskorte N, Mur M, Ruff DA, Kiani R, Bodurka J, Esteky H, et al. Matching categorical object representations in inferior temporal cortex of man and monkey.
- [4] Kriegeskorte N, Mur M, Bandettini P. Representational similarity analysis - connecting the branches of systems neuroscience.
- [5] Torgerson WS. Multidimensional scaling: I. Theory and method. *Psychometrika*.
- [6] Cichy RM, Pantazis D, Oliva A. Resolving human object recognition in space and time. *Nature neuroscience* 2014; 17(3):455–462. doi: 10.1038/nn.3635 PMID: 24464044.
- [7] Tara N. Sainath, Oriol Vinyals, Andrew Senior, Hasim Sak CONVOLUTIONAL, LONG SHORT-TERM MEMORY, FULLY CONNECTED DEEP NEURAL NETWORKS.
- [8] Mohedano, Eva Salvador, Amaia Porta, Sergi Giró-i-Nieto, Xavier Healy, Graham McGuinness, Kevin O'Connor, Noel Smeaton, Alan. Exploring EEG for Object Detection and Retrieval